Engram：以可扩展查找实现条件记忆

A New Axis of Sparsity for Large Language Models

Xin Cheng et al.

中文原生版

Engram：以可扩展查找实现条件记忆

A New Axis of Sparsity for Large Language Models

Xin Cheng, Wangding Zeng, Damai Dai, Qinyu Chen, Bingxuan Wang, Zhenda Xie, Kezhao Huang, Xingkai Yu, Zhewen Hao, Yukun Li, Han Zhang, Huishuai Zhang, Dongyan Zhao, Wenfeng Liang

Peking University DeepSeek-AI

摘 要

混合专家（MoE）通过条件计算扩展模型容量，但 Transformer 缺少原生的知识查找原语，只能以计算低效地模拟检索过程。为此，我们提出**条件记忆**（conditional memory）这一互补的稀疏性维度，并以 Engram 加以实例化：该模块对经典 N-gram 嵌入做了现代化改造，支持 $O(1)$ 查表。通过形式化**稀疏分配**（Sparsity Allocation）问题，我们揭示出一条 U 形缩放定律，用以优化神经计算（MoE）与静态记忆（Engram）之间的权衡。据此，我们将 Engram 扩展至 270 亿参数，在严格等参数、等 FLOPs 的条件下全面优于 MoE 基线。尤其值得注意的是，尽管记忆模块本应主要裨益知识检索（如 MMLU +3.4；CMMLU +4.0），我们在通用推理（如 BBH +5.0；ARC-Challenge +3.7）以及代码/数学领域（HumanEval +3.0；MATH +2.4）观察到了更大的增益。机制分析表明，Engram 让主干网络的早期层摆脱静态重建的负担，等效地加深了用于复杂推理的网络。此外，把局部依赖交给查表处理，可以释放注意力容量去聚焦全局上下文，从而大幅提升长上下文检索能力（如 Multi-Query NIAH：84.2 → 97.0）。最后，Engram 确立了“面向基础设施的效率”：其确定性寻址支持运行时从主机内存预取，开销可以忽略不计。我们期待条件记忆成为下一代稀疏模型不可或缺的建模原语。代码见：https://github.com/deepseek-ai/Engram。

关键词：条件记忆；条件计算；混合专家；稀疏性；缩放定律；长上下文

目录

第 1 章 引言 **4**

第 2 章 架构 **6**
2.1 概述 6
2.2 基于哈希 N-gram 的稀疏检索 6
2.3 上下文感知门控 7
2.4 与多分支架构的集成 7
2.5 系统效率：计算与存储的解耦 9

第 3 章 缩放定律与稀疏性分配 **10**
3.1 MoE 与 Engram 之间的最优分配比例 10
3.2 无限存储机制下的 Engram 11

第 4 章 大规模预训练 **12**
4.1 实验设置 12
4.2 实验结果 14

第 5 章 长上下文训练 **15**
5.1 实验设置 15
5.2 实验结果 15

第 6 章 分析 **17**
6.1 Engram 在功能上是否等价于增加模型深度？ 17
6.2 结构消融与层级敏感性 19
6.3 敏感性分析 20
6.4 系统效率 20

第 7 章 相关工作 **22**

第 8 章 结论 **24**

参考文献 **25**

附录 A 模型架构与超参数详述 **34**

附录 B 完整基准测试曲线 **35**

附录 C 词元压缩案例研究 **36**

第 1 章 引言

稀疏性（sparsity）是智能系统中反复出现的设计原则，从生物神经回路（Lennie, 2003; Olshausen and Field, 1997）一直延续到当代大语言模型（LLM）。目前，这一原则主要借助混合专家（Mixture-of-Experts, MoE）（Dai et al., 2024; Shazeer et al., 2017）实现，即通过条件计算扩展模型容量。由于 MoE 能够在不按比例增加计算量的前提下大幅扩张模型规模，它已成为前沿模型事实上的标准配置（Comanici et al., 2025; Guo et al., 2025; Team et al., 2025）。

尽管这一条件计算范式取得了成功，语言信号内在的异质性仍提示结构层面存在可观的优化空间。具体而言，语言建模包含两类性质不同的子任务：组合推理（compositional reasoning）与知识检索（knowledge retrieval）。前者需要深度、动态的计算，而文本中有相当一部分内容——如命名实体与固定套语——是局部的、静态的、高度模式化的（Constant et al., 2017; Erman, 2000）。经典 N-gram 模型（Brants et al., 2007; Liu et al., 2024b; Nguyen, 2024）能有效刻画这类局部依赖，说明这些规律天然适合以计算代价极低的查表方式表示。然而标准 Transformer（Vaswani et al., 2017）缺少原生的知识查找原语，当前的大模型只能通过计算去模拟检索过程。例如，解析一个常见的多词元实体，需要消耗早期若干层注意力与前馈网络的算力（Ghandeharioun et al., 2024; Jin et al., 2025）（见表 3）。这一过程实质上是在运行时高昂地重建一张静态查找表，把宝贵的串行深度浪费在本可由更高层推理承担的小事上。

为使模型架构与这种语言学上的二元性相匹配，我们主张引入一条互补的稀疏性维度：**条件记忆**（conditional memory）。条件计算通过稀疏激活参数来处理动态逻辑（Bengio et al., 2013; Shazeer et al., 2017），条件记忆则依靠稀疏查找操作，为固定知识取回静态嵌入。作为对该范式的初步探索，我们重新审视 N-gram 嵌入（Bojanowski et al., 2017）这一典型实例：以局部上下文为键，通过常数时间 $O(1)$ 的查找访问一张大规模嵌入表（Huang et al., 2025a; Pagnoni et al., 2025; Tito Svenstrup et al., 2017; Yu et al., 2025）。我们的研究表明，这种静态检索机制或许出人意料地能成为现代 MoE 架构的理想补充——但前提是设计得当。本文提出 Engram，这是一个以经典 N-gram 结构为基础、并融入分词器压缩、多头哈希、上下文感知门控与多分支集成等现代改造的条件记忆模块（详见第 2 章）。

为量化这两种原语之间的协同效应，我们提出**稀疏分配**（Sparsity Allocation）问题：在总参数量固定的前提下，容量应当如何在 MoE 专家与 Engram 记忆之间分配？实验揭示出一条清晰的 U 形缩放定律，说明即便看似简单的查表机制，一旦被当作一等的建模原语，也能成为神经计算不可或缺的补充。依据该分配定律，我们把 Engram 扩展到 270 亿参数规模。与严格等参数、等 FLOPs 的 MoE 基线相比，Engram-27B 在多个领域都取得了更高的效率。关键在于，增益并不局限于以记忆容量见长的知识密集型任务（如 MMLU：+3.4；CMMLU：+4.0；MMLU-Pro：+1.8），我们在通用推理（如 BBH：+5.0；ARC-Challenge：+3.7；DROP：+3.3）与代码/数学领域（如 HumanEval：+3.0；MATH：+2.4；GSM8K：+2.2）上观察到更显著的提升。

借助 LogitLens（nostalgebraist, 2020）与 CKA（Hendrycks et al., 2021a）的机制分析，我们定位了这些增益的来源：Engram 使主干网络不必在早期层重建静态知识，从而为复杂推理腾出更多有效深度。与此同时，把局部依赖交给查表处理后，注意力容量得以聚焦全局上下文，因而在长上下文场景中表现突出——在 LongPPL（Fang et al.）与 RULER（Hsieh et al.）上大幅超越基线（如 Multi-Query NIAH：97.0 对 84.2；Variable Tracking：89.0 对 77.0）。

最后，我们把“面向基础设施的效率”确立为一等原则。与 MoE 的动态路由不同，Engram 采用确定性 ID 支持运行时预取，使通信与计算相互重叠。实验结果显示，把一张 1000 亿参数的嵌入表卸载到主机内存，额外开销可以忽略（$< 3\%$）。这表明 Engram 能有效绕开 GPU 显存限制，为更激进的参数扩张铺平道路。

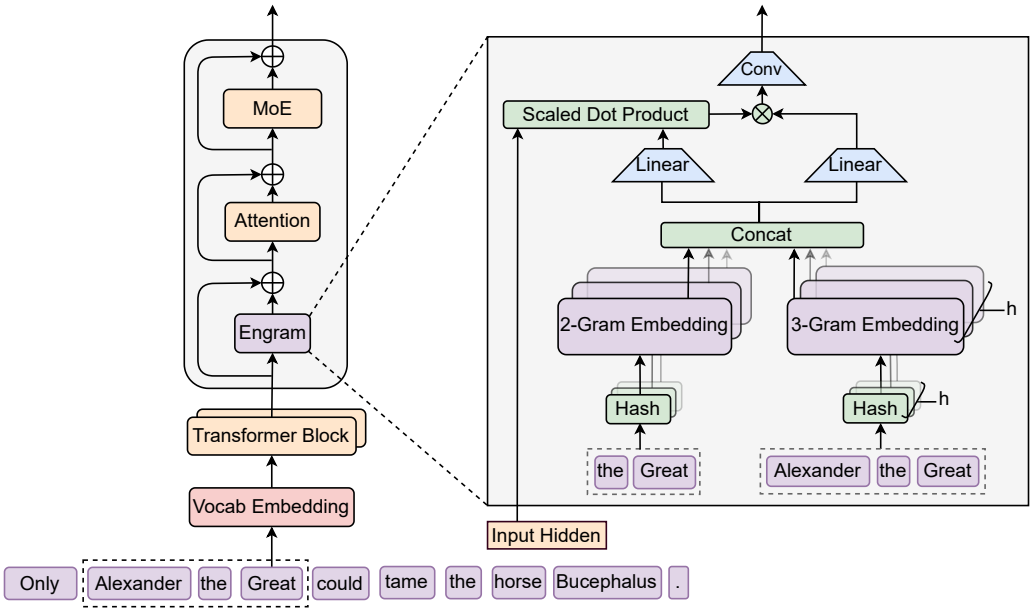


图 1　Engram 架构。该模块通过检索静态 N-gram 记忆，并经由上下文感知门控将其与动态隐藏状态融合，从而增强主干网络。该模块仅应用于特定层，以将记忆与计算解耦，同时保持标准的输入嵌入与反嵌入（un-embedding）模块不变。

第 2 章 架构

2.1 概述

如图 1 所示，Engram 是一个条件记忆模块，通过在结构上将静态模式存储与动态计算分离，用于增强 Transformer 主干网络。形式化地，给定输入序列 $X = (x_1, \dots, x_T)$ 以及第 ℓ 层的隐藏状态 $\mathbf{H}^{(\ell)} \in \mathbb{R}^{T \times d}$，该模块分两个功能阶段处理每个位置 t：检索与融合。首先，如第 2.2 节所述，我们抽取并压缩后缀 N-gram，经由哈希确定性地检索静态嵌入向量。随后，如第 2.3 节所述，这些检索到的嵌入由当前隐藏状态动态调制，并经一个轻量级卷积进一步精炼。最后，我们在第 2.4 节讨论与多分支架构的集成，并在第 2.5 节讨论系统级设计。

2.2 基于哈希 N-gram 的稀疏检索

第一阶段将局部上下文映射到静态记忆条目，包含两个环节：分词器压缩，以及通过确定性哈希检索嵌入。

分词器压缩。N-gram 模型通常直接作用于分词器的输出，而标准子词分词器优先保证*无损重建*（lossless reconstruction），往往给语义等价的词（例如 Apple 与 ␣apple）分配互不相同的 ID（Kudo and Richardson, 2018; Li et al., 2023b）。为了最大化语义密度，我们实现了一个词表投影层。具体而言，我们预先构造一个满射函数 $P : V \to V'$，它依据规范化后的文本等价关系——采用 NFKC（Whistler, 2025）、转小写等——将原始 token ID 折叠为规范 ID（canonical ID）。在实际运行中，对于 128k 词表的分词器，这一过程使有效词表规模缩减 23%（见附录 C）。形式化地，对于位置 t 处的 token，我们将其原始 IDx_t 映射为规范 ID$x'_t = P(x_t)$，并据此时序构成后缀 N-gram$g_{t,n} = (x'_{t-n+1}, \dots, x'_t)$。

多头哈希。直接为所有可能的 N-gram 构成的组合空间参数化是不可行的。我们沿用 Tito Svenstrup et al. (2017) 的做法，采用基于哈希的方案。为缓解冲突，我们对每个 N-gram 阶数 n 使用 K 个互不相同的哈希头。每个哈希头 k 经由一个确定性函数 $\varphi_{n,k}$，把压缩后的上下文映射为嵌入表 $\mathbf{E}_{n,k}$（表大小 $M_{n,k}$ 为素数）中的某个索引：

$$z_{t,n,k} \triangleq \varphi_{n,k}(g_{t,n}), \qquad \mathbf{e}_{t,n,k} = \mathbf{E}_{n,k}[z_{t,n,k}]. \tag{1}$$

在实践中，$\varphi_{n,k}$ 实现为一个轻量的乘法-XOR（multiplicative-XOR）哈希。我们把检索到的全部嵌入拼接起来，构成最终的记忆向量 $\mathbf{e}_t \in \mathbb{R}^{d_{\text{mem}}}$：

$$\mathbf{e}_t \triangleq \Big\|_{n=2}^{N} \Big\|_{k=1}^{K} \mathbf{e}_{t,n,k}. \tag{2}$$

2.3 上下文感知门控

检索到的嵌入 $\mathbf{e}_t$ 是与上下文无关的先验。然而它们是静态的，天然缺乏上下文适应能力，并可能因哈希冲突或一词多义而引入噪声（Haber and Poesio, 2024）。为增强表达能力并消解这种歧义，我们采用一种受注意力机制（Bahdanau et al., 2015; Vaswani et al., 2017）启发的上下文感知门控机制。具体而言，我们把当前隐藏状态 $\mathbf{h}_t$——它已通过前序注意力层聚合了全局上下文——用作动态查询（Query），而检索到的记忆 $\mathbf{e}_t$ 则同时充当键（Key）与值（Value）投影的来源：

$$\mathbf{k}_t = \mathbf{W}_K \mathbf{e}_t, \qquad \mathbf{v}_t = \mathbf{W}_V \mathbf{e}_t \tag{3}$$

其中 $\mathbf{W}_K$、$\mathbf{W}_V$ 是可学习的投影矩阵。为保证梯度稳定性（Dehghani et al., 2023），我们在计算门控标量之前，先对查询与键施加 RMSNorm（Zhang and Sennrich, 2019）：

$$\alpha_t = \sigma\left(\frac{\mathrm{RMSNorm}(\mathbf{h}_t)^\top \mathrm{RMSNorm}(\mathbf{k}_t)}{\sqrt{d}}\right). \tag{4}$$

门控输出定义为 $\tilde{\mathbf{v}}_t = \alpha_t \cdot \mathbf{v}_t$。这一设计强制实现语义对齐：当检索到的记忆 $\mathbf{e}_t$ 与当前上下文 $\mathbf{h}_t$ 相矛盾时，门控 α_t 会趋于零，从而有效抑制噪声。

最后，为了扩大感受野并增强模型的非线性能力，我们引入一个短的深度因果卷积（depth-wise causal convolution）（Gu et al., 2022; Peng et al., 2023）。令 $\tilde{\mathbf{V}} \in \mathbb{R}^{T\times d}$ 表示门控值的序列。取核大小 w（设为 4）、膨胀率 δ（设为最大 N-gram 阶数）与 SiLU 激活（Elfwing et al., 2018），最终输出 $\mathbf{Y}$ 的计算方式为：

$$\mathbf{Y} = \mathrm{SiLU}\left(\mathrm{Conv1D}(\mathrm{RMSNorm}(\tilde{\mathbf{V}}))\right) + \tilde{\mathbf{V}}, \tag{5}$$

随后再经过标准的注意力层与混合专家层。关键在于，Engram 并非应用于每一层；其具体放置位置由第 2.5 节所述的系统级延迟约束决定。

2.4 与多分支架构的集成

在本工作中，我们没有采用标准的单流连接（He et al., 2016），而是选用更先进的多分支架构作为默认主干网络，这得益于其更强的建模能力（Larsson et al., 2017; Szegedy et al., 2015; Xie et al., 2025; Zhu et al., 2025）。该架构的一个鲜明特征是把残差流扩展为 M 条并行分支，信息流动由可学习的连接权重加以调制。

尽管 Engram 模块在本质上与拓扑无关（topology-agnostic），要把它适配到这一多分支框架，仍需在效率与表达能力之间进行结构性优化。具体而言，我们实施一种参数共享策略：单个稀疏嵌入表与值投影矩阵 $\mathbf{W}_V$ 在全部 M 条分支之间共享，而 M 个互不相同的键投影矩阵 $\{\mathbf{W}_K^{(m)}\}_{m=1}^{M}$ 则用于实现各分支特有的门控行为。对第 m 条分支，门控标量的计算方式为：

$$\alpha_t^{(m)} = \sigma\left(\frac{\mathrm{RMSNorm}(\mathbf{h}_t^{(m)})^\top \mathrm{RMSNorm}(\mathbf{W}_K^{(m)}\mathbf{e}_t)}{\sqrt{d}}\right). \tag{6}$$

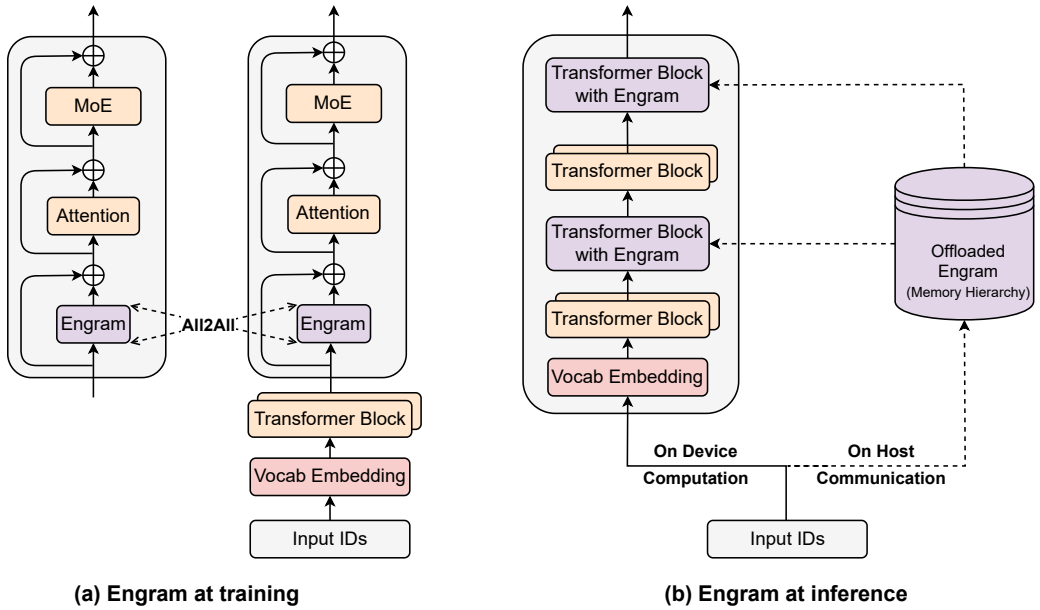


图 2　Engram 的系统实现。（a）训练阶段：大规模嵌入表在可用 GPU 之间分片；采用 All-to-All 通信原语跨设备检索被激活的嵌入行。（b）推理阶段：Engram 表被卸载至主机内存。借助确定性的检索逻辑，主机异步地预取并传输嵌入，使通信与设备上前序 Transformer 块的计算相互重叠。

随后，检索到的记忆由这些独立的门控作用于共享的值向量：$\mathbf{u}_t^{(m)} = \alpha_t^{(m)} \cdot (\mathbf{W}_V \mathbf{e}_t)$。这一设计允许把线性投影——一个 $\mathbf{W}_V$ 与 M 个互不相同的 $\mathbf{W}_K^{(m)}$——融合为一次稠密的 FP8 矩阵乘法，从而最大化现代 GPU 的算力利用率。除非另有说明，所有实验均采用这一集成方式，并与流形约束超连接（Manifold-Constrained Hyper-Connections）（$M = 4$）（Xie et al., 2025）相结合。

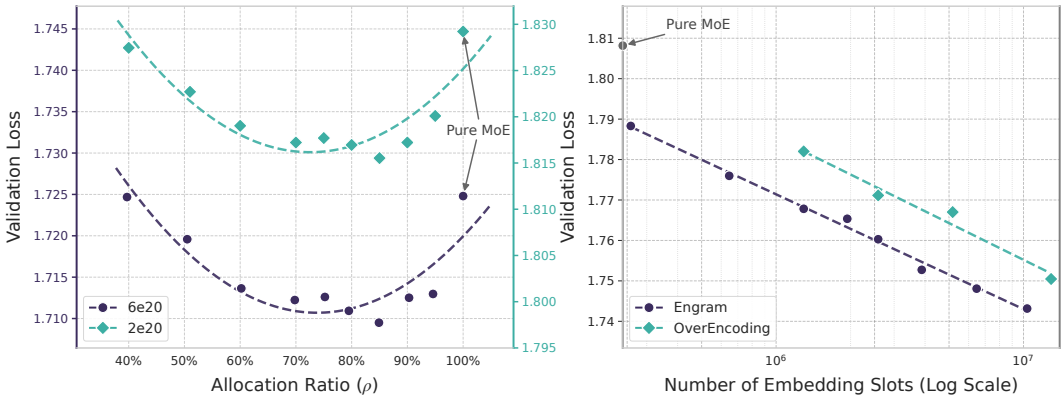


图 3　稀疏性分配与 Engram 的缩放。左：不同分配比例 ρ 下的验证损失，图中给出两个计算预算（2×10^{20} 与 6×10^{20} FLOPs）；两种情形均呈 U 形，且混合分配优于纯 MoE。右：无限存储机制下的缩放行为；验证损失随嵌入数量的增加呈对数线性趋势。

2.5 系统效率：计算与存储的解耦

扩展记忆增强模型常常受限于 GPU 高带宽显存（HBM）的有限容量。然而，Engram 的确定性检索机制天然支持把参数存储与计算资源解耦。与依赖运行时隐藏状态进行动态路由的 MoE 不同，Engram 的检索索引只取决于输入词元序列。这种可预测性使得训练与推理两侧都可以采用专门的优化策略，如图 2 所示。

在训练阶段，为了容纳大规模嵌入表，我们采用标准的模型并行方式，把嵌入表分片到各块可用 GPU 上。前向传播中用一个 All-to-All 通信原语收集被激活的行，反向传播中用它分发梯度，从而使总存储容量能够随加速器数量线性扩展。

在推理阶段，这种确定性使得预取与重叠（prefetch-and-overlap）策略成为可能。由于存储索引在前向传播开始之前就已经确定，系统可以通过 PCIe 从充裕的主机内存中异步取回嵌入向量。为了有效掩盖通信延迟，Engram 模块被放置在骨干网络的特定层上，利用前面各层的计算作为缓冲，避免 GPU 因等待而空转。这要求一种硬件与算法协同设计的策略：把 Engram 放得更深，可以延长用于隐藏延迟的计算窗口；但第 6.2 节的消融实验表明，建模性能更倾向于尽早介入，以便卸载局部模式的重构。因此，最优的放置位置必须同时满足建模约束与系统延迟约束。

此外，自然语言的 N-gram 天然服从 Zipf 分布（Chao and Zipf, 1950; Piantadosi, 2014），即一小部分模式承担了绝大多数存储访问。这一统计性质催生了多级缓存层次（Multi-Level Cache Hierarchy）：高频访问的嵌入可以缓存在更快的存储层级（如 GPU HBM 或主机 DRAM）中，而长尾的罕见模式则驻留在更慢、容量更大的介质（如 NVMe SSD）上。这种分层使 Engram 能够扩展到海量存储容量，同时对有效延迟的影响极小。

第 3 章 缩放定律与稀疏性分配

作为条件记忆的一种实例化，Engram 在结构上与 MoE 专家提供的条件计算形成互补。本节研究这种对偶结构的缩放性质，以及应当如何最优地分配稀疏容量。具体而言，我们的研究围绕两个关键问题展开：

1. 有限约束下的分配（Allocation under Finite Constraints）。在总参数量与训练计算量都固定（等参数 Iso-parameter 与等 FLOPs Iso-FLOPs）时，应当如何在 MoE 专家与 Engram 嵌入之间划分稀疏容量？
2. 无限存储情形（Infinite Memory Regime）。考虑到 Engram 开销为 $O(1)$、不随规模增长，如果放宽或激进地扩大存储预算，Engram 自身会呈现怎样的缩放行为？

3.1 MoE 与 Engram 之间的最优分配比例

等计算资源设定。我们借助三个参数量指标来分析这一权衡。其中，P_{tot} 表示可训练参数总量，不含词表嵌入与 LM 头；P_{act} 表示每个词元的激活参数量，该量决定训练开销（FLOPs）；$P_{\text{sparse}} \triangleq P_{\text{tot}} - P_{\text{act}}$ 表示非激活参数，即在不产生计算开销的前提下可用于扩大模型规模的“空闲”参数预算（例如未被选中的专家或未被检索的嵌入）。

在每个 FLOPs 预算内，我们都固定 P_{tot} 与 P_{act}，使各模型拥有相同的参数量和相同的每词元 FLOPs。对 MoE 而言，P_{act} 由被选中的 top-k 个专家决定，未被选中专家的参数则计入 P_{sparse}；对 Engram 而言，每个词元只检索常数个槽位，因此增加嵌入槽位的数量只会提高 P_{tot}，而不会增加每词元 FLOPs。

分配比例。我们把分配比例 $\rho \in [0, 1]$ 定义为分配给 MoE 专家容量的那部分非激活参数预算的占比：

$$P_{\text{MoE}}^{(\text{sparse})} = \rho\, P_{\text{sparse}}, \qquad P_{\text{Engram}} = (1-\rho)\, P_{\text{sparse}}. \tag{7}$$

- $\rho = 1$ 对应纯 MoE 模型（全部非激活参数都是被路由的专家）。
- $\rho < 1$ 则减少被路由专家的数量，并把释放出来的参数重新分配给 Engram 嵌入槽位。

实验方案。我们在两个计算规模下评估这一权衡，并在两种设定中保持恒定的稀疏比例 $P_{\text{tot}}/P_{\text{act}} \approx 10$：

- $C = 2 \times 10^{20}$ FLOPs：$P_{\text{tot}} \approx 5.7\text{B}$，$P_{\text{act}} = 568\text{M}$。基线（$\rho = 1$）共有 106 个专家。[20]
- $C = 6 \times 10^{20}$ FLOPs：$P_{\text{tot}} \approx 9.9\text{B}$，$P_{\text{act}} = 993\text{M}$。基线（$\rho = 1$）共有 99 个专家。[20]

对于不同的 ρ，我们只通过调整被路由专家的数量和 Engram 嵌入槽位的数量来构造对应的模型。所有运行都使用完全相同的训练流程与优化超参数。

结果与分析。图 3（左）显示，验证损失与分配比例 ρ 之间一致地呈 U 形关系。引人注目的是，即使把 MoE 分配削减到 $\rho \approx 40\%$，Engram 模型的性能也能与纯 MoE 基线（$\rho = 100\%$）相当（即在 5.7B 模型中总共 46 个专家，在 9.9B 模型中总共 43 个专家）。此外，纯 MoE 基

线并非最优：把大约 20%–25% 的稀疏参数预算重新分配给 Engram，可以得到最好的性能。定量来看，在 10B 规模（$C = 6 \times 10^{20}$）下，验证损失从 1.7248（$\rho = 100\%$）改善到 1.7109[20]（接近最优值 $\rho \approx 80\%$，$\Delta = 0.0139$）。关键的是，这一最优点的位置在不同规模之间保持稳定（$\rho \approx 75\%$–80%），表明在固定稀疏度下，所考察的各个规模上存在稳健的分配偏好。观察到的 U 形证实了两个模块之间的结构互补性：

- MoE 占主导（$\rho \to 100\%$）：模型缺少承载静态模式的专用存储，只能通过加深网络和增加计算来低效地重建这些模式。
- Engram 占主导（$\rho \to 0\%$）：模型失去条件计算能力，损害需要动态、依赖上下文进行推理的任务；在这种情形下，存储无法替代计算。

3.2 无限存储机制下的 Engram

第 3.1 节在固定参数预算下优化了分配。现在我们探索与之互补的设定：激进的存储扩展。这项研究的动机，正是第 2.5 节所详述的 Engram 把存储与计算解耦的独特能力。

实验方案。我们使用一个固定的 MoE 骨干网络，其 $P_{\text{tot}} \approx 3\text{B}$、$P_{\text{act}} = 568\text{M}$，并训练 1000 亿词元以保证收敛。在这个骨干之上，我们附加一个 Engram 表，并把槽位数 M 从 2.58×10^5 扫描到 1.0×10^7（额外引入约 130 亿参数）。基线方面，我们与 OverEncoding（Huang et al., 2025a）进行对比，该方法通过取平均把 N-gram 嵌入融合进词表嵌入。需要说明的是，SCONE（Yu et al., 2025）等工作虽然也研究大规模嵌入，但它们主要面向推理，并引入了额外模块（*f-gram* 模型）和额外的训练 FLOPs，因而与本研究严格的等计算约束不兼容。

结果。图 3（右）表明，扩大存储槽位的数量会使验证损失获得清晰而持续的改进。在所考察的整个范围内，曲线严格遵循幂律（在对数空间中呈线性），说明 Engram 提供了一个可预测的缩放旋钮：更大的存储可以持续带来收益，而不需要任何额外计算。关键在于缩放效率：OverEncoding 的直接平均方法虽然也能从更大的存储表中获益，但 Engram 在相同的存储预算下释放出大得多的缩放潜力。结合第 3.1 节的分配定律，这些结果验证了条件记忆是一条独特且可扩展的稀疏容量维度，它与 MoE 的条件计算互为补充。

第 4 章 大规模预训练

凭借所提出的 Engram 架构和由经验导出的分配定律，我们把 Engram 扩展到数十亿参数规模，以检验它在真实语言模型预训练中的有效性。具体而言，我们训练四个模型：（1）Dense-4B（总参数 4.1B）、（2）MoE-27B

（26.7B 总参数量）、(3) Engram-27B（26.7B 总参数量），以及 (4) Engram-40B（39.5B 总参数量）。所有模型都使用完全相同的数据课程（词元预算与顺序一致）进行训练，且激活参数数量严格对齐。

4.1 实验设置

训练数据与模型配置。所有模型都在 2620 亿词元的语料上预训练，分词器沿用 DeepSeek-v3（Liu et al., 2024a），词表规模为 128k。在建模方面，除非另行明确说明，所有模型都遵循一套一致的默认设置，以保证受控比较。我们使用一个隐藏层大小为 2560 的 30 层 Transformer。每个模块集成一个具有 32 个头的多头潜在注意力（Multi-head Latent Attention, MLA）（DeepSeek-AI et al., 2024），并通过扩展率为 4 的 mHC（Xie et al., 2025）连接到 FFN（前馈网络）。所有模型均使用 Muon（Jordan et al., 2024; Team et al., 2025）优化；详细超参数见附录 A。我们实例化了四个不同的模型：

- Dense-4B 充当基线模型。它沿用上文描述的主干架构，并在每个模块中都加入一个标准的稠密 FFN。
- MoE-27B 用 DeepSeekMoE 模块（Dai et al., 2024）替换标准的稠密 FFN。该模型配置了 72 个路由专家和 2 个共享专家（每个词元激活 top-$k = 6$ 个路由专家），总参数量扩展至 26.7B，同时保持与 Dense-4B 相同的激活参数量。
- Engram-27B 严格地从 MoE-27B 架构推导而来，以保证比较公平。我们把路由专家数从 72 缩减到 55，并将腾出的参数重新分配给一个 5.7B 参数的嵌入模块（$\rho = 74.3\%$），使模型总规模保持 26.7B 不变。就 Engram 的配置而言，我们把该模块实例化在第 2 层与第 15 层，并将最大 N-gram 长度设为 3、头数设为 8、维度设为 1280。在优化方面，嵌入参数用 Adam（Kingma, 2014）更新，学习率按 5× 缩放且不使用权重衰减；卷积参数则初始化为零，以便在训练开始时严格保持恒等映射。
- Engram-40B 保留与 Engram-27B 相同的主干与计算预算，但把稀疏嵌入模块扩展到 18.5B 参数（总参数量 39.5B）。该模型旨在考察 Engram 的缩放特性。

评估协议。我们在一套涵盖语言建模、知识、推理、阅读理解以及代码与数学的多样化基准上评估模型。对每个基准，我们都遵循标准的提示协议和评估指标。

- 语言建模：我们报告 The Pile（Gao et al., 2020）测试集上的损失，以及一个与训练数据同分布的验证集上的损失。
- 知识与推理：MMLU（Hendrycks et al., 2021a）、MMLU-Redux（Gema et al., 2025）、MMLU-Pro（Wang et al., 2024b）、CMMLU（Li et al., 2024）、C-Eval（Huang et al., 2023）、AGIEval（Zhong et al., 2024）、ARC-Easy/Challenge（Clark et al., 2018）、TriviaQA（Joshi et al., 2017）、

表 1 稠密模型、MoE 模型与 Engram 模型的预训练性能对比。所有模型均在 262B 词元上训练，激活参数量（3.8B）严格对齐。Engram-27B 通过把路由专家的参数重新分配给一个 5.7B 参数的 Engram 记忆模块（专家数从 72 → 55），与 MoE-27B 保持参数总量一致；Engram-40B 则在保持激活参数预算不变的前提下，把 Engram 记忆进一步扩大（18.5B 参数）。完整的训练期基准轨迹见附录 B。

基准（指标）	样例数	Dense-4B	MoE-27B	Engram-27B	Engram-40B
总参数量		4.1B	26.7B	26.7B	39.5B
激活参数量（不含词元嵌入）		3.8B	3.8B	3.8B	3.8B
训练词元数		262B	262B	262B	262B
专家（共享 + 路由，top-k）		–	2 + 72 (top-6)	2 + 55 (top-6)	2 + 55 (top-6)
Engram 参数量		–	–	5.7B	18.5B
语言建模					
Pile（损失）	–	2.091	1.960	1.950	1.942
验证集（损失）	–	1.768	1.634	1.622	1.610
知识与推理					
MMLU（准确率）	5-shot	48.6	57.4	60.4	60.6
MMLU-Redux（准确率）	5-shot	50.7	60.6	64.0	64.5
MMLU-Pro（准确率）	5-shot	21.1	28.3	30.1	31.3
CMMLU（准确率）	5-shot	47.9	57.9	61.9	63.4
C-Eval（准确率）	5-shot	46.9	58.0	62.7	63.3
AGIEval（准确率）	0-shot	29.1	38.6	41.8	45.9
ARC-Easy（准确率）	25-shot	76.8	86.5	89.0	90.1
ARC-Challenge（准确率）	25-shot	59.3	70.1	73.8	76.4
TriviaQA（精确匹配）	5-shot	33.0	48.8	50.7	51.8
TriviaQA-ZH（精确匹配）	5-shot	62.8	74.8	76.3	77.9
PopQA（精确匹配）	15-shot	15.1	19.2	19.4	21.2
CCPM（准确率）	0-shot	72.2	79.6	87.1	87.7
BBH（精确匹配）	3-shot	42.8	50.9	55.9	57.5
HellaSwag（准确率）	0-shot	64.3	71.8	72.7	73.1
PIQA（准确率）	0-shot	63.8	71.9	73.5	76.5
WinoGrande（准确率）	5-shot	64.0	67.6	67.8	68.1
阅读理解					
DROP（F1）	1-shot	41.6	55.7	59.0	60.7
RACE-Middle（准确率）	5-shot	72.4	80.9	82.8	83.3
RACE-High（准确率）	5-shot	66.0	75.4	78.2	79.2
C3（准确率）	0-shot	57.7	60.1	63.6	61.8
代码与数学					
HumanEval（Pass@1）	0-shot	26.8	37.8	40.8	38.4
MBPP（Pass@1）	3-shot	35.4	46.6	48.2	46.2
CruxEval-i（精确匹配）	0-shot	27.6	30.7	32.2	36.2
CruxEval-o（精确匹配）	0-shot	28.7	34.1	35.0	35.3
GSM8K（精确匹配）	8-shot	35.5	58.4	60.6	62.6
MGSM（精确匹配）	8-shot	27.0	46.8	49.4	52.4
MATH（精确匹配）	4-shot	15.2	28.3	30.7	30.6

TriviaQA-ZH（内部）、PopQA（Mallen et al., 2023）、CCPM（Li et al., 2021）、BBH（Suzgun et al., 2023）、HellaSwag（Zellers et al., 2019）、PIQA（Bisk et al., 2020）和 WinoGrande（Sakaguchi et al., 2021）。

- 阅读理解：DROP（Dua et al., 2019）、RACE（Middle/High）（Lai et al., 2017）和 C3（Sun et al., 2020）。
- 代码与数学：HumanEval（Chen et al., 2021）、MBPP（Austin et al., 2021）、CruxEval（Gu et al., 2024）、GSM8K（Cobbe et al., 2021）、MGSM（Shi et al., 2023）和 MATH（Hendrycks et al., 2021b）。

4.2 实验结果

表 1 汇总了主要结果。首先，与先前文献一致（Borgeaud et al., 2022; He, 2024; Shazeer et al., 2017），稀疏架构相比稠密模型展现出更优的缩放定律。在相同的训练算力预算下，三种稀疏变体（MoE-27B、Engram-27B/40B）在所有基准上都显著超过等 FLOPs（iso-FLOPs）的 Dense-4B 基线。

表 2 长上下文性能对比。括号中的数值（如（50k, 1.62））表示长上下文扩展之前的预训练步数及对应的损失。两项关键发现：(1) Engram-27B 仅用 82% 的预训练 FLOPs（41k 对比 50k）便达到基线的长上下文 PPL（LongPPL）（Fang et al.）水平，同时在 RULER（Hsieh et al.）上取得显著更高的准确率；(2) 在等预训练损失（46k）与等预训练 FLOPs（50k）两种设置下，Engram-27B 在所有指标上均大幅超过基线。加粗表示最优，下划线表示次优。

模型	LongPPL（32k）				RULER（32k）							
	困惑度（↓）				NIAH 准确率（↑）					其他任务（↑）		
	书籍	论文	代码	L-CoT	S	MK	MV	MQ	VT	CWE	FWE	QA
MoE-27B (50k, 1.63)	4.38	2.91	2.49	14.16	100.0	88.0	92.7	84.2	77.0	4.5	73.0	34.5
Engram-27B (41k, 1.66)	4.37	2.92	2.50	14.26	99.6	88.3	93.0	89.5	83.2	3.8	99.6	44.0
Engram-27B (46k, 1.63)	4.19	2.84	2.45	13.59	97.6	89.0	95.5	97.0	87.2	4.3	98.6	37.5
Engram-27B (50k, 1.62)	4.14	2.82	2.44	13.41	99.3	89.3	96.5	97.0	89.0	5.9	99.3	40.5

更重要的是，Engram-27B 在参数总量对齐（iso-parameter）且 FLOPs 对齐（iso-FLOPs）的 MoE-27B 基线上一致地带来改进。有意思的是，这些提升并不局限于知识密集型任务（如 MMLU：+3.0、MMLU-Pro：+1.8、CMMLU：+4.0），尽管从直觉上看记忆容量正是在这类任务上最有利。我们在通用推理领域（如 BBH：+5.0、ARC-Challenge：+3.7、DROP：+3.3）以及代码与数学推理（如

HumanEval：+3.0、MBPP：+1.6、GSM8K：+2.2、MATH：+2.4）上观察到幅度更大的改进。为了降低基准噪声的影响并直观呈现训练动态，我们在附录 B 中给出了预训练期间的完整基准轨迹。这些结果支持了我们的假设：引入一个专门的知识查表原语，能够带来把全部稀疏预算都投向条件计算所无法达到的表示效率。

最后，扩展到 Engram-40B 进一步降低了预训练损失，并在大多数基准上提升了性能。虽然它尚未在每个任务上都严格胜过 Engram-27B，但这很可能是训练不充分造成的结果。我们观察到，随着训练接近尾声，Engram-40B 与各基线之间的训练损失差距仍在持续拉大，这说明扩大的记忆容量在当前词元预算内还没有完全饱和。

第 5 章 长上下文训练

通过把局部依赖建模卸载给静态查表，Engram 架构为管理全局上下文保留了宝贵的注意力容量。本节中，我们通过长上下文扩展训练（Gao et al., 2025; Peng et al., 2024）对这一结构优势做实证检验。借助一个把架构贡献与基础模型能力区分开的严格评估协议，我们证明 Engram 在长程检索与推理任务上带来显著收益。

5.1 实验设置

训练细节。为了获得长上下文能力，我们采用 DeepSeek-V3（Liu et al., 2024a）提出的上下文扩展策略。在预训练阶段之后，我们应用 YaRN（Peng et al., 2024）进行上下文窗口扩展，在一个 32768 词元上下文的训练阶段内训练 5,000 步（合 300 亿词元的高质量长上下文数据）。超参数为缩放系数 $s = 10$、$\alpha = 1$、$\beta = 32$，以及缩放因子 $f = 0.707$。

模型配置。我们在四种不同的模型配置间比较上下文扩展效果。MoE-27B 与 Engram-27B 均采用最终的预训练检查点（50k 步）。此外，为了严格衡量架构效率，我们另为 Engram-27B 选取 41k 与 46k 步两个中间检查点。尽管初始化阶段各不相同，所有变体都经历**完全相同**的上下文扩展训练协议。关键在于，之所以选取 Engram-27B（46k），是因为它与训练完全的 MoE-27B（50k）具有相同的预训练损失。由此构造出一个受控的“等损失（Iso-Loss）”设置，确保上下文扩展过程中出现的任何性能差异都可归因于架构本身，而非模型的起点质量。

评测基准。我们采用 LongPPL（Fang et al.）与 RULER（Hsieh et al.）评估长上下文性能。对于 LongPPL，我们构建了覆盖四类内容的评测集：长篇书籍、研究论文、代码仓库以及长思维链（CoT）轨迹。对于 RULER，我们在聚合为 8 类的 14 个子集上进行评测：大海捞针（Needle-in-a-Haystack）任务的单键（S）、多键（MK）、多值（MV）与多查询（MQ）变体，多跳变量追踪（VT）、常见词抽取（CWE）、高频词抽取（FWE）以及问答（QA）。

5.2 实验结果

评测结果汇总于表 2。为了准确评估 Engram 架构的贡献，我们的分析分两步进行：第一步，把基模型能力的影响与架构设计解耦；第二步，开展受控分析。

1. **超越注意力机制的长上下文能力。**注意力机制与位置编码为上下文处理提供了结构性基础（Press et al., 2022; Su et al., 2024; Xiao et al., 2024; Yang et al., 2025），但我们的结果表明，长上下文性能并非仅由架构先验决定。观察 Engram（41k $\rightarrow$ 50k）的轨迹可以发现，即使模型架构完全相同、上下文扩展阶段的计算预算也固定不变，长上下文性能仍随预训练的推进单调提升。这说明长上下文性能与基模型的通用建模能力内在耦合。因此，严谨的架构对比必须通过校准基模型损失来控制这一混杂变量，而不能仅仅对齐训练步数。
2. **受控条件下的架构优势。**依据上述原则，我们将 Engram 与 MoE 基准进行对比。在控制基模型能力之后，Engram 模块的效率优势清晰显现：

- **等损失（Iso-Loss）设置（46k vs. 基准）**：该设置严格隔离了架构效率。将 Engram-27B（46k）与训练完全的 MoE-27B（50k）——即预训练损失对齐的两个模型——相比，Engram 取得了显著优势：它在复杂检索任务上胜过基准（例如 Multi-Query NIAH：97.0 vs. 84.2；VT：87.2 vs. 77.0）。
- **等计算量（Iso-FLOPs）设置（50k vs. 基准）**：在标准的等算力预算下，Engram-27B（50k）进一步拉大了这一差距，在各评测项上全面确立最高性能。
- **极端设置（约 82% 计算量）**：即便是提前停止的 Engram-27B（41k），面对训练完全的 MoE-27B（50k）依然极具竞争力：它在 LongPPL 上与基准持平，在 RULER 上反超基准，凸显出 Engram 架构的内在优势。

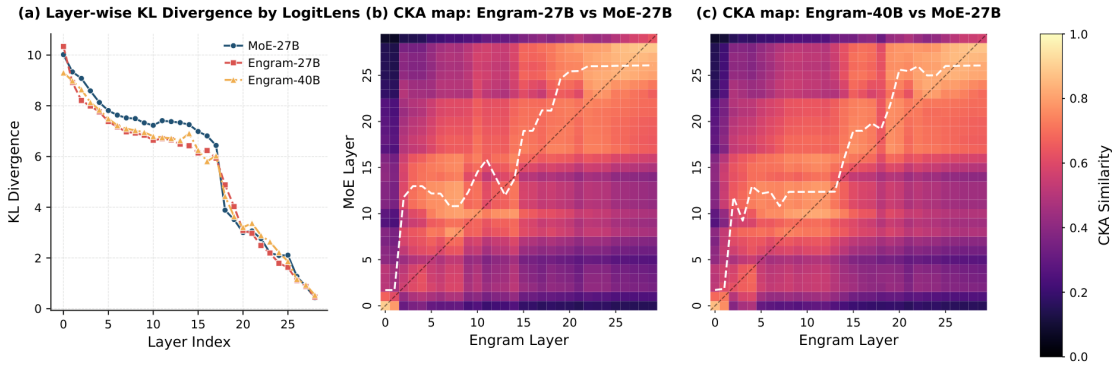


图 4　表征对齐与收敛速度分析。(a) 基于 LogitLens（nostalgebraist, 2020）的逐层 KL 散度：浅层中始终更低的散度说明 Engram 加速了预测收敛。(b-c) 由 CKA（Kornblith et al., 2019）计算得到的相似度热图：高相似度对角线的明显上移，表明 Engram 的浅层在功能上等价于 MoE 模型更深的各层，相当于有效增加了模型深度。

第 6 章 分析

本节考察 Engram 的内部机制，包括其有效深度（第 6.1 节）、核心模块设计（第 6.2 节）与参数敏感性（第 6.3 节）。此外，我们还评测开启卸载（offloading）时的推理吞吐（第 6.4 节），并以一个案例研究作结（第 6.5 节）。

6.1 Engram 在功能上是否等价于增加模型深度？

当前的 LLM 缺乏专门的知识查表原语，只能依靠计算来模拟记忆检索。如表 3 所示，为了识别实体“Diana, Princess of Wales”，LLM 必须消耗多层注意力与前馈网络来逐步组合特征（Ghandeharioun et al., 2024; Jin et al., 2025; Li and Subramani, 2025），而这一过程在理论上本可通过一次知识查表操作加以识别。

基于此，我们推测：通过为模型配备显式的知识查表能力，Engram 使模型免于执行特征组合的早期阶段，从而有效模拟了模型深度的增加。为验证这一假设，我们采用两种机制可解释性工具：LogitLens（Belrose et al., 2023; nostalgebraist, 2020）与中心化核对齐分析（Centered Kernel Alignment, CKA）（Davari et al., 2023; Kornblith et al., 2019）。

6.1.1 加速的预测收敛

我们首先利用 LogitLens（nostalgebraist, 2020）分析预测在各层之间的演化。

通过用最终的 LM 头投影每个中间层的隐藏状态，我们计算中间输出分布与模型最终输出分布之间的 KL 散度（Kullback-Leibler divergence；Kullback and Leibler, 1951）。该指标量化了一个潜在表示距离“随时可用于预测”还有多近（Belrose et al., 2023; Csordás et al., 2025）。

图 4(a) 给出逐层 KL 散度。与 MoE 基准相比，两个 Engram 变体都表现出系统性更小的 KL 散度，且这一差距在最前面的若干块中最为明显。Engram 曲线的下降更陡，说明模型完成特征组合要快得多。这一观察与我们的假设一致：通过显式访问外部知识，Engram 减少了所需的计算步骤，从而在网络层级的更早位置便得到高置信度的有效预测。

表 3 实体解析示例，改编自 Ghandeharioun et al. (2024)。该表展示 LLM 如何通过多层注意力与前馈网络逐步融合上下文词元，以构建实体“Diana, Princess of Wales”的内部表示。“潜在状态翻译”列展示 PatchScope（Ghandeharioun et al., 2024）针对最后一个词元“Wales”自动生成的文本，而“解读”列给出原作者提供的人工解释。

层	潜在状态翻译	解读
1-2	Country in the United Kingdom	Wales
3	Country in Europe	Wales
4	Princess of Wales$_{\text{(unspecific)}}$	Title held by female sovereigns in their own right or by queens consort
5	Princess of Wales$_{\text{(unspecific)}}$	Title given to the wife of the Prince of Wales (and later King)
6	Diana, $_{\text{Princess of Wales}}$	Diana, Princess of Wales (1961-1997), the first wife of Prince Charles, Prince of Wales, who was famous for her beauty and human-$_{\text{itarian work}}$

6.1.2 表征对齐与有效深度

为进一步考察 Engram 的各层是否与基准模型更深的各层语义对应，我们采用中心化核对齐（CKA）——一种被广泛接受的、用于比较表征结构的指标（Kornblith et al., 2019; Kriegeskorte et al., 2008）。给定两组表示 X 与 Y（例如来自不同模型或不同层的激活），则 CKA 定义为

$$\mathrm{CKA}(K, L) = \frac{\mathrm{HSIC}(K, L)}{\sqrt{\mathrm{HSIC}(K, K)\,\mathrm{HSIC}(L, L)}} \tag{8}$$

式中，HSIC 即希尔伯特-施密特独立性准则（Hilbert-Schmidt Independence Criterion）（Gretton et al., 2005）。我们采用带 HSIC 无偏估计量的小批量实现（Davari et al., 2023），并在 Few-NERD 数据集（Ding et al., 2021）上评测，抽取命名实体最后一个词元所对应的隐藏状态。

为严格量化逐层对应关系，我们首先计算成对 CKA 相似度矩阵 $S \in [0, 1]^{L \times L}$，其中 L 为层数。随后我们引入一个软对齐指标 a_j，将其定义为对 Engram 第 j 层而言与之最相似的 top-k 个 MoE 层的加权质心：

$$a_j = \frac{\sum_{i \in I_j} S_{i,j} \cdot i}{\sum_{i \in I_j} S_{i,j}}, \qquad I_j = \operatorname*{argtopk}_i(S_{i,j}). \tag{9}$$

式中，$S_{i,j}$ 表示 MoE 第 i 层与 Engram 第 j 层之间的相似度得分。

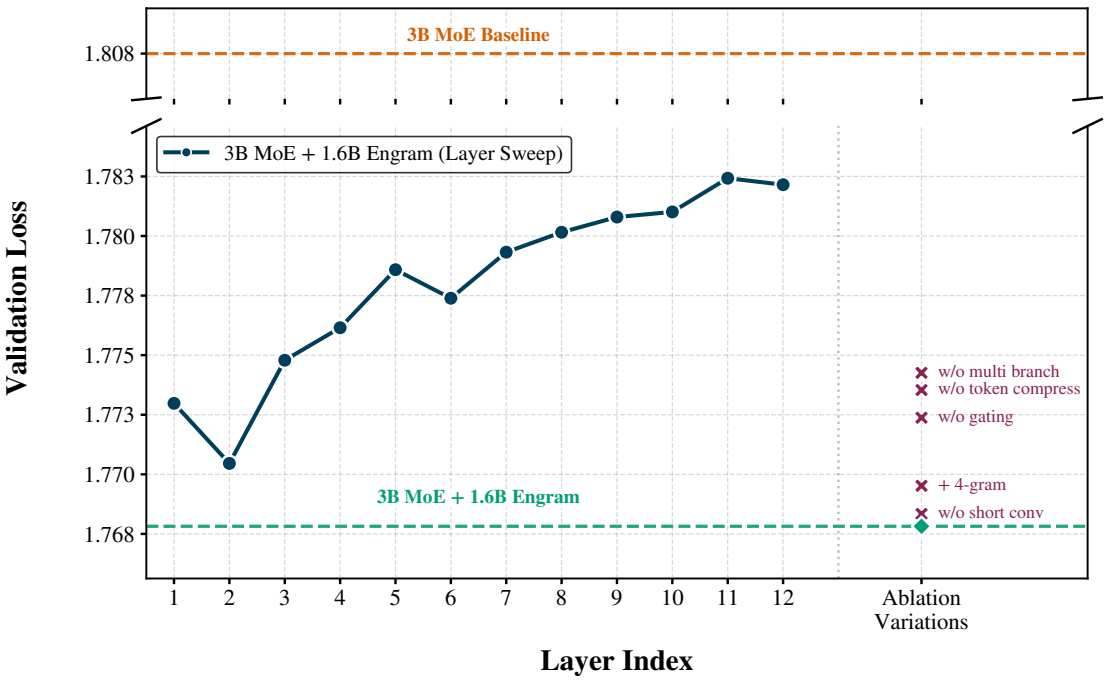


图 5　架构消融结果。我们在两种设置下将 3B MoE 基线与各 Engram 变体进行对比：(1) 层级敏感性（深蓝色曲线）：扫描单个 Engram 模块的插入深度，确认早期注入（第 2 层）最优，而插入到更深层则效果退化。(2) 组件消融（右侧标记）：从参考配置中逐一移除子模块，凸显出多分支集成、分词器压缩与上下文感知门控的重要性。

指标 a_j 可作为与 Engram 第 j 层相对应的“有效 MoE 深度”的稳健代理，并利用 top-k 过滤（$k = 5$）来抑制低相似度噪声。

图 4(b)-(c) 将软对齐曲线（白色虚线）叠加在相似度热图上。可以看到，相似度整体明显偏离对角线向更浅位置上移，这意味着在相当宽的层范围内都有 $a_j > j$。例如，Engram-27B 在第 5 层形成的表征，与 MoE 基线约第 12 层的表征最为接近。

这种一致的对角线偏移与 LogitLens 结果（第 6.1.1 节）相互印证，说明 Engram 在更早的层就建立起了更深层的表征。这也验证了我们的核心假设：借助显式查表绕过早期阶段的特征组合，Engram 在功能上等价于增加了模型的有效深度。

6.2 结构消融与层级敏感性

本节在受控设置下对 Engram 做消融，以考察各关键模块设计的有效性。除非另有说明，骨干网络为 12 层的 3B MoE 模型（0.56B 激活参数），在 100B 词元上训练。图 5 报告验证损失。橙色虚线表示 3B MoE 基线（验证损失 =1.808）。

参考配置。我们为骨干网络加装一块固定为 1.6B 参数的 Engram 记忆。参考模型使用 $\{2, 3\}$-gram，并把 Engram 插入第 2 层和第 6 层，取得验证损失 =1.768，相对 MoE 基线有大幅改善（$\Delta = 0.04$）。下文所有结构消融均相对于该参考配置来定义。

记忆应当注入何处？为考察深度敏感性，我们把 Engram 预算固定在 1.6B，但将其合并为单个 Engram 模块，并把插入层从第 1 层扫描到第 12 层（图 5 中深蓝色的“Layer Sweep”曲线）。该实验揭示出 Engram 放置位置中一种固有的取舍。

布局中的取舍。尽早注入 Engram，可以让它在骨干网络消耗计算深度之前，先替它完成局部模式的重构，这与骨干网络自然的分层处理方式相吻合 (Ghandeharioun et al., 2024; Jin et al., 2025; Li and Subramani, 2025; Tenney et al., 2019)。但这样做的代价是门控精度下降：早期隐藏状态尚未通过注意力聚合到足够的全局上下文，各并行分支也缺乏细粒度调制所需的表征分化 (Xie et al., 2025; Zhu et al., 2025)。因此，最优放置位置需要在两者之间取得平衡：(i) 趁早卸载静态局部模式，(ii) 等到更深的层再用上下文信息更充分的查询进行门控。

扫描结果显示，第 2 层给出了单层插入的最佳性能（验证损失 =1.770），优于第 1 层，且随插入点加深而逐渐变差。这说明一轮注意力已足以产生对门控有实际意义的上下文化隐藏状态 h_t，同时插入位置又足够浅，可以取代骨干网络底层的局部聚合。

第 2 层是“单次插入”约束下的最优解；但我们也发现，把同样 1.6B 的记忆拆成两个更小的模块（通过减小嵌入维度 d_{mem} 实现），分别放在第 2 层和第 6 层，效果反而更好（验证损失 =1.768）。这种分层设计将早期干预与后期充分的上下文门控结合起来，调和了上述取舍。更重要的是，分层插入还带来实实在在的系统效益：如第 2.5 节所述，它能更好地利用存储层级。

哪些组件真正重要？从参考配置出发，在 Engram 参数预算保持固定的前提下逐一消融各项设计选择，结果以标记点的形式标在图 5 中。我们发现有三个组件贡献了最显著的收益：(i) 多分支骨干内部的分支专属融合，(ii) 上下文感知门控，(iii) 分词器压缩。移除其中任何一项，都会造成验证损失的最大幅度回退。具体而言，对于“w/o multi branch”（去多分支）消融，我们保留 mHC 骨干结构，但把分支专属门控替换为单一 Engram 融合，作用在预映射 H^{pre} 之后的隐藏状态上 (Xie et al., 2025)。

其他改动的效应较小：去掉轻量的深度卷积只会让性能略有下降。在 1.6B 预算固定的情况下，给 4-gram 分配容量则略显不佳——这很可能是因为它稀释了更高频的 2/3-gram 模式的容量——不过我们并不排除在更大的记忆规模下，高阶 N-gram 可能变得有益。

6.3 敏感性分析

为刻画 Engram 模块的功能贡献，我们在保持骨干不变的情况下，于推理阶段完全抑制稀疏嵌入的输出，据此评估模型。关键在于，这种事后消融会带来训练与推理的不一致，在能力多样的复杂任务上可能引入噪声。因此，我们优先分析事实性知识（Factual Knowledge）与阅读理解（Reading Comprehension）——它们位于敏感性谱系的两端——在这项压力测试下信噪比最高。

如图 6 所示，结果呈现出鲜明的功能分野：事实性知识类基准性能断崖式崩塌，只保留原始性能的 29%–44%（例如 TriviaQA 仅剩 29%），印证了 Engram 模块是参数化知识的主要存储库；相反，阅读理解任务则展现出很强的韧性，保留了 81%–93%（例如 C3 达到 93%），说明以上下文为依据的任务主要依靠骨干网络的注意力机制，而非 Engram。

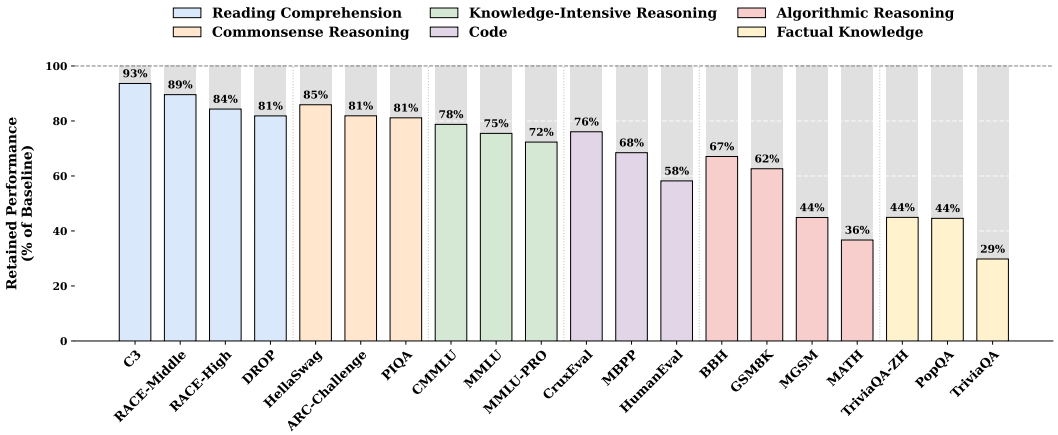


图 6　Engram 消融下的性能保持比例。事实性知识高度依赖 Engram 模块，而阅读理解任务大部分由骨干网络保住。

6.4 系统效率

Engram 相对基于路由的 MoE 还有一个关键的系统优势：其稀疏激活由显式且静态的哈希 ID 来寻址。这带来严格确定的访存模式：一旦词元序列给定，下一次 Engram 查表所需的索引即告固定，可以在对应层执行之前预先算好。

实验设置。我们基于 nano-vLLM[1]——工业界标准 vLLM 引擎 (Kwon et al., 2023) 的精简原型——搭建了一个推理测试平台。为获得不受 MoE 专家并行通信模式干扰的干净延迟基线，我们在两个稠密骨干（Dense-4B 与 Dense-8B）上进行测试。我们在第二个 Transformer 块中插入

[1] https://github.com/GeeeekExplorer/nano-vllm

一个规模达 100B 参数的 Engram 层，整个嵌入表驻留在主机 DRAM 中。推理期间，系统异步预取 Engram 层所需的嵌入，使 PCIe 传输与第一个块的计算相重叠。

结果。如表 4 所示，卸载一块 100B 参数的嵌入表所付出的吞吐代价可以忽略不计，最高仅为 8B 骨干上的 2.8%。这证实了早期稠密块的计算强度提供了足够的时间窗口来掩盖检索延迟。关键在于，每一步的有效通信量取决于被激活的槽位数量，而非嵌入表的总规模。

需要指出，这项实验充当的是一个保守的基线。第 2.5 节的分层设计利用 Zipf 局部性把高频条目缓存到 HBM 中，而我们的实验设置却强制所有检索都经由 PCIe 总线从主机内存读取。而这一基线

表 4 端到端推理吞吐量。我们测量把一个 100B 参数的 Engram 层完全卸载到主机内存时的推理吞吐量。

实验设置		
硬件	NVIDIA H800	
工作负载	512 条序列	
序列长度	Uniform(100, 1024)	
	基座模型配置	吞吐 (tok/s)
4B-Dense		
基线		9,031.62
+ 100B Engram（CPU 卸载）		8,858.28
8B-Dense		
基线		6,315.52
+ 100B Engram（CPU 卸载）		6,140.02

仅带来极小的开销，有力地说明：经过充分优化、具备局部性感知的实现，几乎不会造成吞吐损失。

6.4.1 案例研究：门控可视化

第 2.3 节中，我们介绍了上下文感知门控机制，其设计目的是动态调节检回的静态记忆整合进主干的强度。为了从经验上检验 Engram 是否按设计意图工作，我们在图 7 中可视化了 Engram-27B 在多个样本上的门控标量 α_t 的取值。[2]

结果显示出一种鲜明的选择性模式：门控机制在局部静态模式完成时持续激活（以红色显示）。在英语样本中，我们观察到多词元命名实体（如“Alexander the Great”“the Milky Way”）与套语式短语（如“By the way”“Princess of Wales”）上出现强激活。这一行为能够有效地跨语言迁移。在中文样本中，Engram 识别并检索出具有区分度的惯用表达与历史实体，例如“Four Great Inventions”（四大发明）与“Zhang Zhongjing”（张仲景）。这些定性结果证实，Engram 能够成功识别并处理定型化的语言依存关系，有效地免除 Transformer 主干记忆这些静态关联的负担。

[2]如我们的架构设置所述，该模型采用 mHC（M=4），并在第 2 层与第 15 层插入 Engram 模块。因此，对任一给定词元，模型共计算 8 个不同的门控标量。我们观察到，并非每个分支都编码出可解释的激活模式。为使本可视化足够清晰，我们选取并展示与语义模式匹配关联最强的那些门控值。

第 7 章 相关工作

N-gram 建模与嵌入扩展。N-gram 模型源于 Shannon 的框架 (Shannon, 1948)，其依赖局部历史来预测词元，并通常借助平滑技术 (Katz, 1987; Kneser and Ney, 1995) 缓解数据稀疏。尽管为捕捉长程依赖，建模范式已转向神经网络架构 (Bengio et al., 2003)，N-gram 查表的计算效率却在现代表示学习中被保留下来，开创性工作 FastText (Bojanowski et al., 2017) 即为例证。



图 7　Engram 门控机制的可视化。热图的深浅对应门控标量 $\alpha_t \in [0, 1]$ 的大小，红色越深表示激活越强。由于 Engram 作用于后缀 N-gram（此处 $N = 3$），某个特定词元 x_t 上出现高激活，意味着以该词元收尾的前若干词元（例如在 t 处结束的短语）被识别为一种已有效地从记忆中检索回的静态模式。

近来，这一范式以**嵌入扩展**（embedding scaling）的形式重新兴起。Per-Layer Embeddings (Team, 2025) 与 DeepEmbed (RWKV Team, 2025) 等架构通过庞大的嵌入表扩展容量；与之不同的是，一条与我们方法最相关的开创性研究路线，则把组合式 N-gram 结构直接融入表示空间。SuperBPE (Liu et al., 2025) 与 SCONE (Yu et al., 2025) 明确针对高频模式：前者把多词表达式合并为“超词”（superword）词元，后者借助一个辅助编码模型实现。与此并行，OverEncoding (Huang et al., 2025a) 与字节潜在 Transformer（Byte Latent Transformer，BLT）(Pagnoni et al., 2025) 分别采用哈希 N-gram 嵌入，在词元层面与字节层面捕捉局部依赖。这些研究共同表明：借助 N-gram 表示扩展参数规模，能在极小的计算开销下取得成效。尽管上述方法在各自设定下都能带来显著收益，我们的工作却在两个关键维度上与之存在根本分歧。

- 首先，在建模与评测协议方面。已有工作通常把 N-gram 嵌入当作外部附加项，而未在严格公平的对比协议下检验其效率。例如，SCONE (Yu et al., 2025) 只面向推理场景，且依赖会带来额外训练 FLOPs 的辅助模块；类似地，OverEncoding (Huang et al., 2025a) 即便在非等参数设置下，也未能在稀疏 MoE 主干上取得有意义的改进。与之相对，我们把条件记忆当作通过精心设计的 Engram 模块加以实例化的一等建模原语。在**稀疏性分配**（Sparsity Allocation）框架内对这一设计进行严格评测后，我们证明了它相对于严格等参数、等 FLOPs 的 MoE 基线具有明显优势。
- 其次，从系统视角出发，我们主张算法—系统协同设计。已有方法把嵌入严格地置于输入层（Layer 0），这必然使访存与计算串行化 (Huang et al., 2025a; Yu et al., 2025)；Engram 则反其道而行，把记忆策略性地注入更深层，以实现通信—计算重叠。此外，利用 N-gram 固有的 Zipfian（齐夫）分布特性，我们得以最大化硬件存储层级的利用效率。这一整体性设计使 Engram 能够以可忽略的推理开销扩展到海量参数。

混合专家（Mixture-of-Experts）。MoE 架构通过按词元有条件地激活一小部分专家，把模型容量与计算成本解耦，这一范式由 Shazeer 等人 (2017) 提出。随后，GShard (Lepikhin et al., 2020)、

BASE (Lewis et al., 2021)、Switch Transformer (Fedus et al., 2022) 与 GLaM (Du et al., 2022) 等创新，在保持推理成本恒定的同时实现了超线性（super-linear）参数扩展。更晚近地，DeepSeek-MoE (Dai et al., 2024) 展现出更优的效率，借助细粒度专家切分与共享专家隔离，显著超过同等激活参数规模的稠密模型。采用这一架构的最先进模型，如 DeepSeek-V3 (Liu et al., 2024a) 与 Kimi-k2 (Team et al., 2025)，进一步把总参数量推进到数千亿规模。

记忆网络（Memory Network）。记忆增强网络的研究旨在扩展模型容量，而不使计算成本成比例增加，大体可分为参数化与非参数化两类。参数化记忆方法，如 PKM (Lample et al., 2019)、PEER (He, 2024)、Selfmem (Cheng et al., 2023b)、Memory+ (Berges et al., 2025) 与 UltraMem (Huang et al., 2025b,c)，把大规模稀疏键值存储直接集成进模型层，从而在几乎不影响 FLOPs 的情况下显著提升容量。相反，REALM (Guu et al., 2020)、RETRO (Borgeaud et al., 2022; Wang et al., 2023) 与 PlugLM (Cheng et al., 2023a) 等非参数化记忆方法，则把知识存储与模型处理解耦，将外部记忆视为一个可编辑、可扩展的键值存储，使模型无需重新训练即可适应不断演进的信息。

知识存储机制（Mechanisms of Knowledge Storage）。在容量扩展之外，大量研究细致考察了 Transformer 编码与取回事实知识的内部机制。前馈网络（FFN）被普遍假设扮演键值记忆的角色 (Geva et al., 2021)：在这一框架下，第一层充当模式探测器（“键”），第二层则把特定信息投影进残差流（“值”）。这种模块化性质的证据，来自对负责存储不同事实的特定“知识神经元”的识别 (Dai et al., 2022)。因果追踪方法进一步提供了佐证，它把事实回忆的信息流定位到特定的 FFN 层 (Meng et al., 2022)。这些洞见催生了 ROME (Meng et al., 2022) 与 MEMIT (Meng et al., 2023) 等精确的模型编辑算法，使得无需重新训练即可直接更新事实关联。此外，对内部表示的研究——如 Othello-GPT (Li et al., 2023a) 上的工作——表明这些存储机制可能促成了结构化“世界模型”的涌现，而不仅是统计学意义上的记忆。

第 8 章 结论

在本工作中，我们把条件记忆作为对主流条件计算范式（混合专家，MoE）的补充性稀疏性维度引入，旨在解决以动态计算模拟知识检索的低效问题。我们通过 Engram 实例化这一概念：它是对经典 N-gram 嵌入加以现代化的模块，能够对静态模式实现可扩展、恒定时间 O(1) 的查表。

通过对**稀疏性分配**问题的形式化，我们揭示出一条 U 形缩放定律，表明把稀疏容量在 MoE 专家与 Engram 记忆之间做混合分配，严格优于纯 MoE 基线。在该定律的指引下，我们把 Engram 扩展到 27B 参数，在多个领域取得领先的性能。尤其地，尽管记忆模块直观上最直接地助益知识检索，我们观察到它在通用推理、代码与数学上的收益甚至更大。

我们的机制分析揭示，Engram 通过把早期层从静态重构任务中解放出来，有效地“加深”了网络，由此腾出的注意力容量得以专注于全局上下文与复杂推理。这一架构转变带来了长上下文能力的显著提升，LongPPL 与 RULER 上的性能增益即为佐证。最后，Engram 把“基础设施感知的效率”作为一等设计原则来倡导：其确定性寻址使存储与计算得以解耦，从而可以把海量参数表卸载到主机内存，而推理开销几乎可以忽略不计。我们期待条件记忆（conditional memory）成为下一代稀疏模型不可或缺的建模原语。

参考文献

J. Austin, A. Odena, M. Nye, M. Bosma, H. Michalewski, D. Dohan, E. Jiang, C. Cai, M. Terry, Q. Le, et al. Program synthesis with large language models. arXiv preprint arXiv:2108.07732, 2021.

D. Bahdanau, K. Cho, and Y. Bengio.Neural machine translation by jointly learning to align and translate. In Y. Bengio and Y. LeCun, editors, 3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings, 2015. URL http://arxiv.org/abs/1409.0473.

N. Belrose, Z. Furman, L. Smith, D. Halawi, I. Ostrovsky, L. McKinney, S. Biderman, and J. Steinhardt. Eliciting latent predictions from transformers with the tuned lens.arXiv preprint arXiv:2303.08112, 2023.

Y. Bengio, R. Ducharme, P. Vincent, and C. Janvin. A neural probabilistic language model. J. Mach. Learn. Res., 3:1137-1155, 2003. URL https://jmlr.org/papers/v3/bengio03a .html.

Y. Bengio, N. Léonard, and A. Courville. Estimating or propagating gradients through stochastic neurons for conditional computation, 2013. URL https://arxiv.org/abs/1308.3432.

V. Berges, B. Oguz, D. Haziza, W. Yih, L. Zettlemoyer, and G. Ghosh. Memory layers at scale. In Forty-second International Conference on Machine Learning, ICML 2025, Vancouver, BC, Canada, July 13-19, 2025. OpenReview.net, 2025. URL https://openreview.net/forum ?id=ATqGm1WyDj.

X. Bi, D. Chen, G. Chen, S. Chen, D. Dai, C. Deng, H. Ding, K. Dong, Q. Du, Z. Fu, et al. Deepseek llm: Scaling open-source language models with longtermism. arXiv preprint arXiv:2401.02954, 2024.

Y. Bisk, R. Zellers, J. Gao, Y. Choi, et al. Piqa: Reasoning about physical commonsense in natural language. In Proceedings of the AAAI conference on artificial intelligence, volume 34, pages 7432-7439, 2020.

P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov. Enriching word vectors with subword information. Transactions of the association for computational linguistics, 5:135-146, 2017.

S. Borgeaud, A. Mensch, J. Hoffmann, T. Cai, E. Rutherford, K. Millican, G. B. Van Den Driessche, J.-B. Lespiau, B. Damoc, A. Clark, et al. Improving language models by retrieving from trillions of tokens. In International conference on machine learning, pages 2206-2240. PMLR, 2022.

T. Brants, A. C. Popat, P. Xu, F. J. Och, and J. Dean.Large language models in machine translation.In J. Eisner, editor, Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning (EMNLP-CoNLL), pages 858-867, Prague, Czech Republic, June 2007. Association for Computational Linguistics. URL https://aclanthology.org/D07-1090/.

Y. R. Chao and G. K. Zipf. Human behavior and the principle of least effort: An introduction to human ecology. Language, 26:394, 1950. URL https://api.semanticscholar.org/Co rpusID:10182796.

M. Chen, J. Tworek, H. Jun, Q. Yuan, H. P. de Oliveira Pinto, J. Kaplan, H. Edwards, Y. Burda, N. Joseph, G. Brockman, A. Ray, R. Puri, G. Krueger, M. Petrov, H. Khlaaf, G. Sastry, P. Mishkin, B. Chan, S. Gray, N. Ryder, M. Pavlov, A. Power, L. Kaiser, M. Bavarian, C. Winter, P. Tillet, F. P. Such, D. Cummings, M. Plappert, F. Chantzis, E. Barnes, A. Herbert-Voss, W. H. Guss, A. Nichol, A. Paino, N. Tezak, J. Tang, I. Babuschkin, S. Balaji, S. Jain, W. Saunders, C. Hesse, A. N. Carr, J. Leike, J. Achiam, V. Misra, E. Morikawa, A. Radford, M. Knight, M. Brundage, M. Murati, K. Mayer, P. Welinder, B. McGrew, D. Amodei, S. McCandlish, I. Sutskever, and W. Zaremba. Evaluating large language models trained on code, 2021. URL https://arxiv.org/abs/2107.03374.

X. Cheng, Y. Lin, X. Chen, D. Zhao, and R. Yan. Decouple knowledge from paramters for plug-and-play language modeling. In A. Rogers, J. Boyd-Graber, and N. Okazaki, editors, Findings of the Association for

Computational Linguistics: ACL 2023, pages 14288-14308, Toronto, Canada, July 2023a. Association for Computational Linguistics. doi: 10.18653/v1/20 23.findings-acl.901. URL https://aclanthology.org/2023.findings-acl.901/.

X. Cheng, D. Luo, X. Chen, L. Liu, D. Zhao, and R. Yan. Lift yourself up: Retrieval-augmented text generation with self-memory. Advances in Neural Information Processing Systems, 36: 43780-43799, 2023b.

P. Clark, I. Cowhey, O. Etzioni, T. Khot, A. Sabharwal, C. Schoenick, and O. Tafjord. Think you have solved question answering? try arc, the ai2 reasoning challenge. arXiv preprint arXiv:1803.05457, 2018.

K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, et al. Training verifiers to solve math word problems. arXiv preprint arXiv:2110.14168, 2021.

G. Comanici, E. Bieber, M. Schaekermann, I. Pasupat, N. Sachdeva, I. Dhillon, M. Blistein, O. Ram, D. Zhang, E. Rosen, et al. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. arXiv preprint arXiv:2507.06261, 2025.

M. Constant, G. Eryiğit, J. Monti, L. Van Der Plas, C. Ramisch, M. Rosner, and A. Todirascu. Survey: multiword expression processing: a survey. Computational Linguistics, 43(4):837-892, 2017.

R. Csordás, C. D. Manning, and C. Potts. Do language models use their depth efficiently? arXiv preprint arXiv:2505.13898, 2025.

D. Dai, L. Dong, Y. Hao, Z. Sui, B. Chang, and F. Wei. Knowledge neurons in pretrained transformers. In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 8493-8502, 2022.

D. Dai, C. Deng, C. Zhao, R. Xu, H. Gao, D. Chen, J. Li, W. Zeng, X. Yu, Y. Wu, et al. Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models. arXiv preprint arXiv:2401.06066, 2024.

M. Davari, S. Horoi, A. Natik, G. Lajoie, G. Wolf, and E. Belilovsky. Reliability of CKA as a similarity measure in deep learning. In The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023. URL https://openreview.net/forum?id=8HRvyxc606.

DeepSeek-AI, A. Liu, B. Feng, B. Wang, B. Wang, B. Liu, C. Zhao, C. Dengr, C. Ruan, D. Dai, D. Guo, D. Yang, D. Chen, D. Ji, E. Li, F. Lin, F. Luo, G. Hao, G. Chen, G. Li, H. Zhang, H. Xu, H. Yang, H. Zhang, H. Ding, H. Xin, H. Gao, H. Li, H. Qu, J. L. Cai, J. Liang, J. Guo, J. Ni, J. Li, J. Chen, J. Yuan, J. Qiu, J. Song, K. Dong, K. Gao, K. Guan, L. Wang, L. Zhang, L. Xu, L. Xia, L. Zhao, L. Zhang, M. Li, M. Wang, M. Zhang, M. Zhang, M. Tang, M. Li, N. Tian, P. Huang, P. Wang, P. Zhang, Q. Zhu, Q. Chen, Q. Du, R. J. Chen, R. L. Jin, R. Ge, R. Pan, R. Xu, R. Chen, S. S. Li, S. Lu, S. Zhou, S. Chen, S. Wu, S. Ye, S. Ma, S. Wang, S. Zhou, S. Yu, S. Zhou, S. Zheng, T. Wang, T. Pei, T. Yuan, T. Sun, W. L. Xiao, W. Zeng, W. An, W. Liu, W. Liang, W. Gao, W. Zhang, X. Q. Li, X. Jin, X. Wang, X. Bi, X. Liu, X. Wang, X. Shen, X. Chen, X. Chen, X. Nie, X. Sun, X. Wang, X. Liu, X. Xie, X. Yu, X. Song, X. Zhou, X. Yang, X. Lu, X. Su, Y. Wu, Y. K. Li, Y. X. Wei, Y. X. Zhu, Y. Xu, Y. Huang, Y. Li, Y. Zhao, Y. Sun, Y. Li, Y. Wang, Y. Zheng, Y. Zhang, Y. Xiong, Y. Zhao, Y. He, Y. Tang, Y. Piao, Y. Dong, Y. Tan, Y. Liu, Y. Wang, Y. Guo, Y. Zhu, Y. Wang, Y. Zou, Y. Zha, Y. Ma, Y. Yan, Y. You, Y. Liu, Z. Z. Ren, Z. Ren, Z. Sha, Z. Fu, Z. Huang, Z. Zhang, Z. Xie, Z. Hao, Z. Shao, Z. Wen, Z. Xu, Z. Zhang, Z. Li, Z. Wang, Z. Gu, Z. Li, and Z. Xie. Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model, 2024. URL https://arxiv.org/abs/2405.04434.

M. Dehghani, J. Djolonga, B. Mustafa, P. Padlewski, J. Heek, J. Gilmer, A. P. Steiner, M. Caron, R. Geirhos, I. Alabdulmohsin, R. Jenatton, L. Beyer, M. Tschannen, A. Arnab, X. Wang, C. Riquelme Ruiz, M. Minderer, J. Puigcerver, U. Evci, M. Kumar, S. V. Steenkiste, G. F. Elsayed, A. Mahendran, F. Yu, A. Oliver, F. Huot, J. Bastings, M. Collier, A. A. Gritsenko, V. Birodkar, C. N. Vasconcelos, Y. Tay, T. Mensink, A. Kolesnikov, F. Pavetic, D. Tran, T. Kipf, M. Lucic, X. Zhai, D. Keysers, J. J. Harmsen, and N. Houlsby. Scaling vision

transformers to 22 billion parameters. In A. Krause, E. Brunskill, K. Cho, B. Engelhardt, S. Sabato, and J. Scarlett, editors, Proceedings of the 40th International Conference on Machine Learning, volume 202 of Proceedings of Machine Learning Research, pages 7480-7512. PMLR, 23-29 Jul 2023. URL https://proceedings.mlr.press/v202/dehghani23a.html.

N. Ding, G. Xu, Y. Chen, X. Wang, X. Han, P. Xie, H. Zheng, and Z. Liu. Few-nerd: A fewshot named entity recognition dataset. In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), pages 3198-3213, 2021.

N. Du, Y. Huang, A. M. Dai, S. Tong, D. Lepikhin, Y. Xu, M. Krikun, Y. Zhou, A. W. Yu, O. Firat, et al. Glam: Efficient scaling of language models with mixture-of-experts. In International conference on machine learning, pages 5547-5569. PMLR, 2022.

D. Dua, Y. Wang, P. Dasigi, G. Stanovsky, S. Singh, and M. Gardner. DROP: A reading comprehension benchmark requiring discrete reasoning over paragraphs. In J. Burstein, C. Doran, and T. Solorio, editors, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT

2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers), pages 23682378. Association for Computational Linguistics, 2019. doi: 10.18653/V1/N19-1246. URL https://doi.org/10.18653/v1/n19-1246.

S. Elfwing, E. Uchibe, and K. Doya. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning. Neural networks, 107:3-11, 2018.

B. Erman. The idiom principle and the open choice principle. Text-Interdisciplinary Journal for the Study of Discourse, 2000.

L. Fang, Y. Wang, Z. Liu, C. Zhang, S. Jegelka, J. Gao, B. Ding, and Y. Wang. What is wrong with perplexity for long-context language modeling? In The Thirteenth International Conference on Learning Representations.

W. Fedus, B. Zoph, and N. Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. Journal of Machine Learning Research, 23(120):1-39, 2022.

L. Gao, S. Biderman, S. Black, L. Golding, T. Hoppe, C. Foster, J. Phang, H. He, A. Thite, N. Nabeshima, et al. The pile: An 800gb dataset of diverse text for language modeling. arXiv preprint arXiv:2101.00027, 2020.

T. Gao, A. Wettig, H. Yen, and D. Chen. How to train long-context language models (effectively). In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 7376-7399, 2025.

A. P. Gema, J. O. J. Leang, G. Hong, A. Devoto, A. C. M. Mancino, R. Saxena, X. He, Y. Zhao, X. Du, M. R. G. Madani, et al. Are we done with mmlu? In Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), pages 5069-5096, 2025.

M. Geva, R. Schuster, J. Berant, and O. Levy. Transformer feed-forward layers are key-value memories. In Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, pages 5484-5495, 2021.

A. Ghandeharioun, A. Caciularu, A. Pearce, L. Dixon, and M. Geva. Patchscopes: A unifying framework for inspecting hidden representations of language models. In International Conference on Machine Learning, pages 15466-15490. PMLR, 2024.

A. Gretton, O. Bousquet, A. Smola, and B. Schölkopf. Measuring statistical dependence with hilbert-schmidt norms. In International conference on algorithmic learning theory, pages 63-77. Springer, 2005.

A. Gu, K. Goel, and C. Ré. Efficiently modeling long sequences with structured state spaces. In The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022. OpenReview.net, 2022. URL https://openreview.net/forum?id=uY LFoz1vlAC.

A. Gu, B. Rozière, H. J. Leather, A. Solar-Lezama, G. Synnaeve, and S. Wang. Cruxeval: A benchmark for code reasoning, understanding and execution. In Forty-first International Conference on Machine Learning, ICML 2024, Vienna, Austria, July 21-27, 2024. OpenReview.net, 2024. URL https://openreview.net/forum?id=Ffpg52swvg.

D. Guo, D. Yang, H. Zhang, J. Song, R. Zhang, R. Xu, Q. Zhu, S. Ma, P. Wang, X. Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948, 2025.

K. Guu, K. Lee, Z. Tung, P. Pasupat, and M. Chang. Retrieval augmented language model pre-training. In International conference on machine learning, pages 3929-3938. PMLR, 2020.

J. Haber and M. Poesio. Polysemy—Evidence from linguistics, behavioral science, and contextualized language models. Computational Linguistics, 50(1):351-417, Mar. 2024. doi: 10.1162/coli_a_00500. URL https://aclanthology.org/2024.cl-1.10/.

K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 770-778, 2016.

X. O. He. Mixture of a million experts. arXiv preprint arXiv:2407.04153, 2024.

D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt. Measuring massive multitask language understanding. In 9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021. OpenReview.net, 2021a. URL https://openreview.net/forum?id=d7KBjmI3GmQ.

D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt. Measuring mathematical problem solving with the MATH dataset. In J. Vanschoren and S. Yeung, editors, Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks 1, NeurIPS Datasets and Benchmarks 2021, December 2021, virtual, 2021b. URL https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/has h/be83ab3ecd0db773eb2dc1b0a17836a1-Abstract-round2.html.

C.-P. Hsieh, S. Sun, S. Kriman, S. Acharya, D. Rekesh, F. Jia, and B. Ginsburg. Ruler: What's the real context size of your long-context language models? In First Conference on Language Modeling.

H. Huang, D. Zhu, B. Wu, Y. Zeng, Y. Wang, Q. Min, and X. Zhou. Over-tokenized transformer: Vocabulary is generally worth scaling. In Forty-second International Conference on Machine Learning, ICML 2025, Vancouver, BC, Canada, July 13-19, 2025. OpenReview.net, 2025a. URL https://openreview.net/forum?id=gbeZKej40m.

Y. Huang, Y. Bai, Z. Zhu, J. Zhang, J. Zhang, T. Su, J. Liu, C. Lv, Y. Zhang, Y. Fu, et al. C-eval: A multi-level multi-discipline chinese evaluation suite for foundation models. Advances in Neural Information Processing Systems, 36:62991-63010, 2023.

Z. Huang, Y. Bao, Q. Min, S. Chen, R. Guo, H. Huang, D. Zhu, Y. Zeng, B. Wu, X. Zhou, et al. Ultra-memv2: Memory networks scaling to 120b parameters with superior long-context learning. arXiv preprint arXiv:2508.18756, 2025b.

Z. Huang, Q. Min, H. Huang, Y. Zeng, D. Zhu, R. Guo, and X. Zhou. Ultra-sparse memory network. In The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025. OpenReview.net, 2025c. URL https://openreview.n et/forum?id=zjeHLSiNv1.

M. Jin, Q. Yu, J. Huang, Q. Zeng, Z. Wang, W. Hua, H. Zhao, K. Mei, Y. Meng, K. Ding, F. Yang, M. Du, and Y. Zhang. Exploring concept depth: How large language models acquire knowledge and concept at different

layers?In O. Rambow, L. Wanner, M. Apidianaki, H. Al-Khalifa, B. D. Eugenio, and S. Schockaert, editors, Proceedings of the 31st International Conference on Computational Linguistics, COLING 2025, Abu Dhabi, UAE, January 19-24, 2025, pages 558-573. Association for Computational Linguistics, 2025. URL https://acla nthology.org/2025.coling-main.37/.

K. Jordan, Y. Jin, V. Boza, J. You, F. Cesista, L. Newhouse, and J. Bernstein. Muon: An optimizer for hidden layers in neural networks, 2024. URL https://kellerjordan.github.io/p osts/muon/.

M. Joshi, E. Choi, D. S. Weld, and L. Zettlemoyer. Triviaqa: A large scale distantly supervised challenge dataset for reading comprehension. In R. Barzilay and M. Kan, editors, Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, ACL 2017, Vancouver, Canada, July 30 - August 4, Volume 1: Long Papers, pages 1601-1611. Association for Computational Linguistics, 2017. doi: 10.18653/V1/P17-1147. URL https://doi.org/ 10.18653/v1/P17-1147.

S. M. Katz. Estimation of probabilities from sparse data for the language model component of a speech recognizer. IEEE Trans. Acoust. Speech Signal Process., 35(3):400-401, 1987. doi: 10.1109/TASSP.1987.1165125. URL https://doi.org/10.1109/TASSP.1987.1165125.

D. P. Kingma. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 2014.

R. Kneser and H. Ney.Improved backing-off for m-gram language modeling.In 1995 international conference on acoustics, speech, and signal processing, volume 1, pages 181184. IEEE, 1995.

S. Kornblith, M. Norouzi, H. Lee, and G. Hinton. Similarity of neural network representations revisited. In International conference on machine learning, pages 3519-3529. PMlR, 2019.

N. Kriegeskorte, M. Mur, and P. A. Bandettini. Representational similarity analysis-connecting the branches of systems neuroscience. Frontiers in systems neuroscience, 2:249, 2008.

T. Kudo and J. Richardson. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing.In E. Blanco and W. Lu, editors, Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, EMNLP 2018: System Demonstrations, Brussels, Belgium, October 31 - November 4, 2018, pages 66-71. Association for Computational Linguistics, 2018. doi: 10.18653/V1/D18-2012. URL https://doi.org/10.18653/v1/d18-2012.

S. Kullback and R. A. Leibler. On information and sufficiency. The annals of mathematical statistics, 22(1):79-86, 1951.

W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. Gonzalez, H. Zhang, and I. Stoica. Efficient memory management for large language model serving with pagedattention. In Proceedings of the 29th symposium on operating systems principles, pages 611-626, 2023.

G. Lai, Q. Xie, H. Liu, Y. Yang, and E. H. Hovy. RACE: large-scale reading comprehension dataset from examinations. In M. Palmer, R. Hwa, and S. Riedel, editors, Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017, Copenhagen, Denmark, September 9-11, 2017, pages 785-794. Association for Computational Linguistics, 2017. doi: 10.18653/V1/D17-1082. URL https://doi.org/10.18653/v1/d1 7-1082.

G. Lample, A. Sablayrolles, M. Ranzato, L. Denoyer, and H. Jégou. Large memory layers with product keys. Advances in Neural Information Processing Systems, 32, 2019.

G. Larsson, M. Maire, and G. Shakhnarovich. Fractalnet: Ultra-deep neural networks without residuals. In 5th International Conference on Learning Representations, ICLR 2017, Toulon, France, April 24-26, 2017, Conference Track Proceedings. OpenReview.net, 2017. URL https: //openreview.net/forum?id=S1VaB4cex.

P. Lennie. The cost of cortical computation. Current biology, 13(6):493-497, 2003.

D. Lepikhin, H. Lee, Y. Xu, D. Chen, O. Firat, Y. Huang, M. Krikun, N. Shazeer, and Z. Chen. Gshard: Scaling giant models with conditional computation and automatic sharding. arXiv preprint arXiv:2006.16668, 2020.

M. Lewis, S. Bhosale, T. Dettmers, N. Goyal, and L. Zettlemoyer. Base layers: Simplifying training of large, sparse models. In M. Meila and T. Zhang, editors, Proceedings of the 38th International Conference on Machine Learning, volume 139 of Proceedings of Machine Learning Research, pages 6265-6274. PMLR, 18-24 Jul 2021. URL https://proceedings. mlr.press/v139/lewis21a.html.

H. Li, Y. Zhang, F. Koto, Y. Yang, H. Zhao, Y. Gong, N. Duan, and T. Baldwin. Cmmlu: Measuring massive multitask language understanding in chinese. In Findings of the Association for Computational Linguistics: ACL 2024, pages 11260-11285, 2024.

K. Li, A. K. Hopkins, D. Bau, F. B. Viégas, H. Pfister, and M. Wattenberg. Emergent world representations: Exploring a sequence model trained on a synthetic task. In The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023a. URL https://openreview.net/forum?id=DeG07_TcZvT.

M. Li and N. Subramani. Echoes of bert: Do modern language models rediscover the classical nlp pipeline?, 2025. URL https://arxiv.org/abs/2506.02132.

R. Li, L. B. Allal, Y. Zi, N. Muennighoff, D. Kocetkov, C. Mou, M. Marone, C. Akiki, J. Li, J. Chim, Q. Liu, E. Zheltonozhskii, T. Y. Zhuo, T. Wang, O. Dehaene, M. Davaadorj, J. LamyPoirier, J. Monteiro, O. Shliazhko, N. Gontier, N. Meade, A. Zebaze, M. Yee, L. K. Umapathi, J. Zhu, B. Lipkin, M. Oblokulov, Z. Wang, R. M. V, J. T. Stillerman, S. S. Patel, D. Abulkhanov, M. Zocca, M. Dey, Z. Zhang, N. Fahmy, U. Bhattacharyya, W. Yu, S. Singh, S. Luccioni, P. Villegas, M. Kunakov, F. Zhdanov, M. Romero, T. Lee, N. Timor, J. Ding, C. Schlesinger, H. Schoelkopf, J. Ebert, T. Dao, M. Mishra, A. Gu, J. Robinson, C. J. Anderson, B. Dolan-Gavitt, D. Contractor, S. Reddy, D. Fried, D. Bahdanau, Y. Jernite, C. M. Ferrandis, S. Hughes, T. Wolf, A. Guha, L. von Werra, and H. de Vries. Starcoder: may the source be with you! Trans. Mach. Learn. Res., 2023, 2023b. URL https://openreview.net/forum?id=KoFOg41haE.

W. Li, F. Qi, M. Sun, X. Yi, and J. Zhang. Ccpm: A chinese classical poetry matching dataset. arXiv preprint arXiv:2106.01979, 2021.

A. Liu, B. Feng, B. Xue, B. Wang, B. Wu, C. Lu, C. Zhao, C. Deng, C. Zhang, C. Ruan, et al. Deepseek-v3 technical report. arXiv preprint arXiv:2412.19437, 2024a.

A. Liu, J. Hayase, V. Hofmann, S. Oh, N. A. Smith, and Y. Choi. SuperBPE: Space travel for language models. In Second Conference on Language Modeling, 2025. URL https: //openreview.net/forum?id=lcDRvffeNP.

J. Liu, S. Min, L. Zettlemoyer, Y. Choi, and H. Hajishirzi. Infini-gram: Scaling unbounded n-gram language models to a trillion tokens. In First Conference on Language Modeling, 2024b. URL https://openreview.net/forum?id=u2vAyMeLMm.

A. Mallen, A. Asai, V. Zhong, R. Das, D. Khashabi, and H. Hajishirzi. When not to trust language models: Investigating effectiveness of parametric and non-parametric memories. In Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 9802-9822, 2023.

K. Meng, D. Bau, A. Andonian, and Y. Belinkov. Locating and editing factual associations in gpt. Advances in neural information processing systems, 35:17359-17372, 2022.

K. Meng, A. S. Sharma, A. J. Andonian, Y. Belinkov, and D. Bau. Mass-editing memory in a transformer. In The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023. URL https://openreview.n et/forum?id=MkbcAHIYgyS.

T. Nguyen. Understanding transformers via n-gram statistics. Advances in neural information processing systems, 37:98049-98082, 2024.

nostalgebraist. interpreting gpt: the logit lens. LessWrong, 2020. URL https://www.lesswrong.com/posts/AcKRB8wDpdaN6v6ru/interpreting-gpt-the-logit-lens.

B. A. Olshausen and D. J. Field. Sparse coding with an overcomplete basis set: A strategy employed by v1? Vision research, 37(23):3311-3325, 1997.

A. Pagnoni, R. Pasunuru, P. Rodriguez, J. Nguyen, B. Muller, M. Li, C. Zhou, L. Yu, J. E. Weston, L. Zettlemoyer, et al. Byte latent transformer: Patches scale better than tokens. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 9238-9258, 2025.

B. Peng, E. Alcaide, Q. Anthony, A. Albalak, S. Arcadinho, S. Biderman, H. Cao, X. Cheng, M. Chung, L. Derczynski, X. Du, M. Grella, K. K. GV, X. He, H. Hou, P. Kazienko, J. Kocon, J. Kong, B. Koptyra, H. Lau, J. Lin, K. S. I. Mantri, F. Mom, A. Saito, G. Song, X. Tang, J. S. Wind, S. Wozniak, Z. Zhang, Q. Zhou, J. Zhu, and R. Zhu. RWKV: reinventing rnns for the transformer era. In H. Bouamor, J. Pino, and K. Bali, editors, Findings of the Association for Computational Linguistics: EMNLP 2023, Singapore, December 6-10, 2023, pages 1404814077. Association for Computational Linguistics, 2023. doi: 10.18653/V1/2023.FINDINGS-EMNLP.936. URL https://doi.org/10.18653/v1/2023.findings-emnlp.936.

B. Peng, J. Quesnelle, H. Fan, and E. Shippole. Yarn: Efficient context window extension of large language models. In The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024. OpenReview.net, 2024. URL https://openre view.net/forum?id=wHBfxhZu1u.

S. T. Piantadosi. Zipf's word frequency law in natural language: A critical review and future directions. Psychonomic bulletin & review, 21(5):1112-1130, 2014.

O. Press, N. A. Smith, and M. Lewis. Train short, test long: Attention with linear biases enables input length extrapolation.In The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022. OpenReview.net, 2022. URL https://openreview.net/forum?id=R8sQPpGCv0.

RWKV Team. Rwkv architecture history. https://wiki.rwkv.com/basic/architecture .html, 2025. Section "RWKV-V8's DeepEmbed", accessed 2025-12-09.

K. Sakaguchi, R. L. Bras, C. Bhagavatula, and Y. Choi. Winogrande: An adversarial winograd schema challenge at scale. Communications of the ACM, 64(9):99-106, 2021.

C. E. Shannon. A mathematical theory of communication. The Bell system technical journal, 27 (3):379-423, 1948.

N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, and J. Dean.Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. arXiv preprint arXiv:1701.06538, 2017.

F. Shi, M. Suzgun, M. Freitag, X. Wang, S. Srivats, S. Vosoughi, H. W. Chung, Y. Tay, S. Ruder, D. Zhou, D. Das, and J. Wei. Language models are multilingual chain-of-thought reasoners. In The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023. URL https://openreview.net/forum?i d=fR3wGCk-IXp.

J. Su, M. H. M. Ahmed, Y. Lu, S. Pan, W. Bo, and Y. Liu. Roformer: Enhanced transformer with rotary position embedding. Neurocomputing, 568:127063, 2024. doi: 10.1016/J.NEUCOM.2 023.127063. URL https://doi.org/10.1016/j.neucom.2023.127063.

K. Sun, D. Yu, D. Yu, and C. Cardie. Investigating prior knowledge for challenging chinese machine reading comprehension. Transactions of the Association for Computational Linguistics, 8:141-155, 2020.

M. Suzgun, N. Scales, N. Schärli, S. Gehrmann, Y. Tay, H. W. Chung, A. Chowdhery, Q. Le, E. Chi, D. Zhou, et al. Challenging big-bench tasks and whether chain-of-thought can solve them. In Findings of the Association for Computational Linguistics: ACL 2023, pages 13003-13051, 2023.

C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1-9, 2015.

G. Team. Gemma 3n. 2025. URL https://ai.google.dev/gemma/docs/gemma-3n.

K. Team, Y. Zhang, Z. Lin, X. Yao, J. Hu, F. Meng, C. Liu, X. Men, S. Yang, Z. Li, et al. Kimi linear: An expressive, efficient attention architecture. arXiv preprint arXiv:2510.26692, 2025.

I. Tenney, D. Das, and E. Pavlick. Bert rediscovers the classical nlp pipeline. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2019.

D. Tito Svenstrup, J. Hansen, and O. Winther. Hash embeddings for efficient word representations. Advances in neural information processing systems, 30, 2017.

A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. Advances in neural information processing systems, 30, 2017.

B. Wang, W. Ping, P. Xu, L. McAfee, Z. Liu, M. Shoeybi, Y. Dong, O. Kuchaiev, B. Li, C. Xiao, et al. Shall we pretrain autoregressive language models with retrieval? a comprehensive study. In Proceedings of the 2023 conference on empirical methods in natural language processing, pages 7763-7786, 2023.

L. Wang, H. Gao, C. Zhao, X. Sun, and D. Dai. Auxiliary-loss-free load balancing strategy for mixture-of-experts, 2024a. URL https://arxiv.org/abs/2408.15664.

Y. Wang, X. Ma, G. Zhang, Y. Ni, A. Chandra, S. Guo, W. Ren, A. Arulraj, X. He, Z. Jiang, et al. Mmlu-pro: A more robust and challenging multi-task language understanding benchmark. Advances in Neural Information Processing Systems, 37:95266-95290, 2024b.

K. Whistler. Unicode standard annex #15: Unicode normalization forms. Unicode Standard Annex 15, The Unicode Consortium, July 2025. URL https://www.unicode.org/report s/tr15/tr15-57.html. Version Unicode 17.0.0, Revision 57. Accessed 2026-01-04.

G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis. Efficient streaming language models with attention sinks. In The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024. OpenReview.net, 2024. URL https://openreview .net/forum?id=NG7sS51zVF.

Z. Xie, Y. Wei, H. Cao, C. Zhao, C. Deng, J. Li, D. Dai, H. Gao, J. Chang, L. Zhao, S. Zhou, Z. Xu, Z. Zhang, W. Zeng, S. Hu, Y. Wang, J. Yuan, L. Wang, and W. Liang. mhc: Manifold-constrained hyper-connections, 2025. URL https://arxiv.org/abs/2512.24880.

S. Yang, Y. Shen, K. Wen, S. Tan, M. Mishra, L. Ren, R. Panda, and Y. Kim. Path attention: Position encoding via accumulating householder transformations. arXiv preprint arXiv:2505.16381, 2025.

D. Yu, E. Cohen, B. Ghazi, Y. Huang, P. Kamath, R. Kumar, D. Liu, and C. Zhang. Scaling embedding layers in language models. arXiv preprint arXiv:2502.01637, 2025.

R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, and Y. Choi. Hellaswag: Can a machine really finish your sentence? In A. Korhonen, D. R. Traum, and L. Màrquez, editors, Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers, pages 4791-4800. Association for Computational Linguistics, 2019. doi: 10.18653/V1/P19-1472. URL https://doi.org/10.18653/v1/p1 9-1472.

B. Zhang and R. Sennrich.Root mean square layer normalization.Advances in neural information processing systems, 32, 2019.

W. Zhong, R. Cui, Y. Guo, Y. Liang, S. Lu, Y. Wang, A. Saied, W. Chen, and N. Duan. Agieval: A human-centric benchmark for evaluating foundation models. In Findings of the Association for Computational Linguistics: NAACL 2024, pages 2299-2314, 2024.

D. Zhu, H. Huang, Z. Huang, Y. Zeng, Y. Mao, B. Wu, Q. Min, and X. Zhou.Hyperconnections. In The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025. OpenReview.net, 2025. URL https://openreview.net /forum?id=9FqARW7dwB.

附录 A 模型架构与超参数详述

表 5 模型架构信息与训练超参数明细

	Dense-4B	MoE-27B	Engram-27B	Engram-40B
总参数量	4.1B	26.7B	26.7B	39.5B
激活参数量	3.8B			
训练词元总量	262B			
层数	30			
隐藏维度	2560			
前置稠密层数	–	1	1	1
路由专家数	–	72	55	55
激活专家数	–	6	6	6
共享专家数	–	2	2	2
负载均衡方法	–	Loss Free (Wang et al., 2024a)		
注意力模块	MLA (DeepSeek-AI et al., 2024)			
RoPE θ	10000			
mHC 扩展率	4			
序列长度	4096			
词表大小	129280			
批大小	1280			
训练步数	50000			
主干优化器	Muon (Jordan et al., 2024)			
嵌入优化器	Adam (Kingma, 2014)			
基础学习率	4e-4			
学习率调度器	Step Decay (Bi et al., 2024)			
权重衰减	0.1			
Engram 维度 d_{mem}	–	–	1280	1280
Engram 词表大小	–	–	2262400	7239680
Engram 注意力头数	–	–	8	8
Engram 层位	–	–	[2,15]	[2,15]
Engram N-gram 阶数	–	–	[2,3]	[2,3]
Engram 联合 mHC	–	–	True	True
Engram 词元压缩	–	–	True	True
Engram Conv 零初始化	–	–	True	True
Engram 学习率倍率	–	–	x5	x5
Engram 权重衰减	–	–	0.0	0.0
Engram 优化器（仅嵌入）	–	–	Adam (Kingma, 2014)	

附录 B 完整基准测试曲线

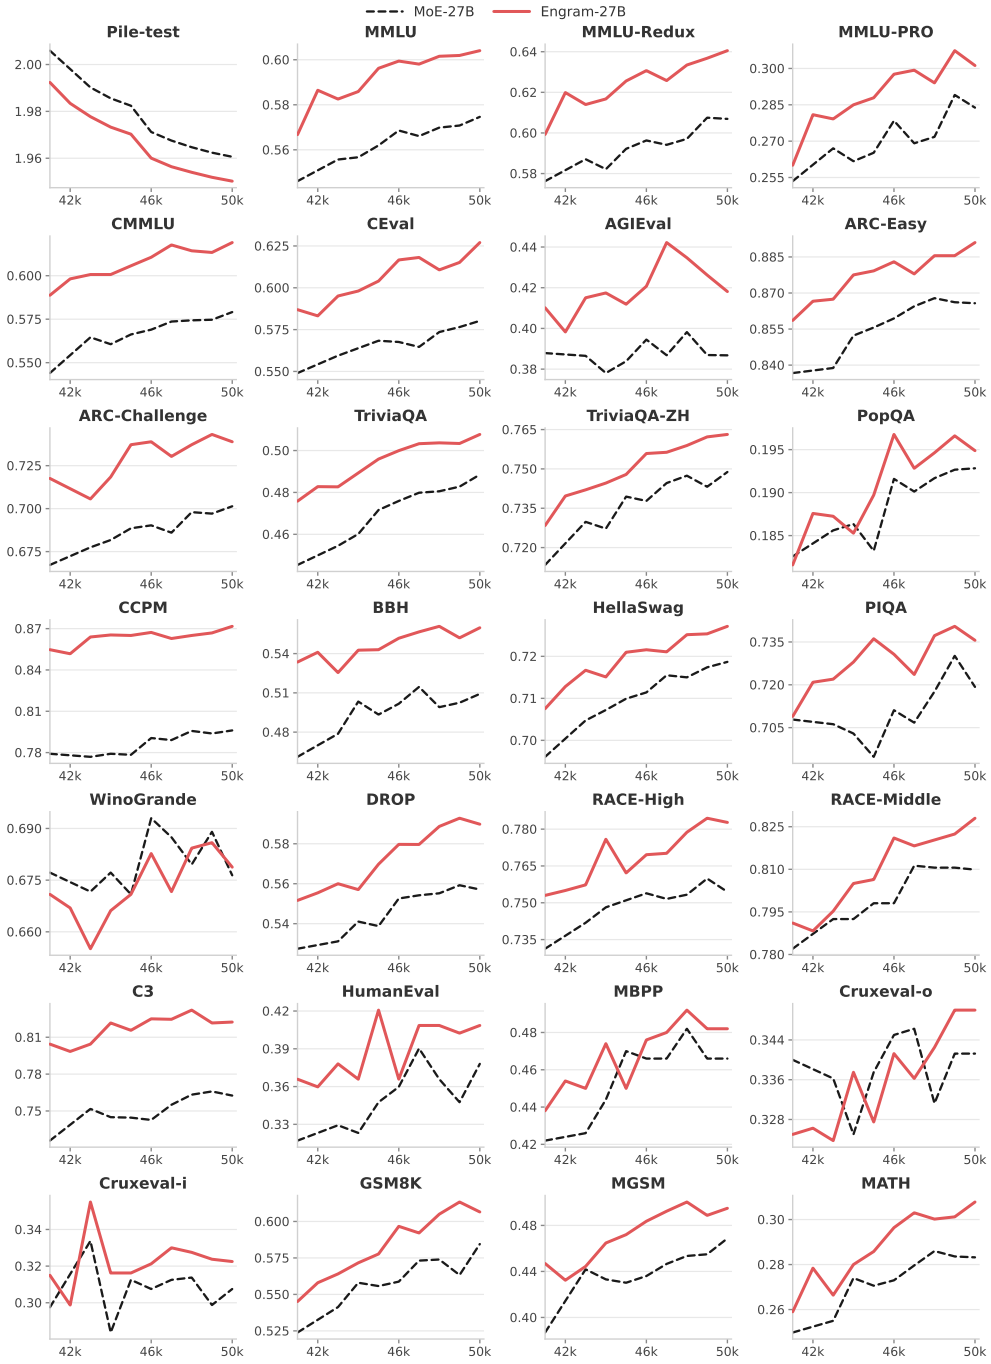


图 8　预训练最后 10k 步的基准测试曲线。

附录 C 词元压缩案例研究

表 6 词元压缩（Tokenizer Compression）所合并词元的 Top-5 示例；我们的 128k 分词器的整体压缩率为 23.43%。

序号	原始词元数	词元	合并/规范化词元列表
1	163	’␣’	’\t’, ’\n’, ’\r’, ’␣’, ’␣␣’, ’\n\n’, ’␣␣␣’, ’␣\n’, …
2	54	’a’	’A’, ’a’, ’␣a’, ’␣A’, ’á’, ’ä’, ’ã’, ’ą’, ’␣à’, ’␣å’, ’â’, …
3	40	’o’	’O’, ’o’, ’␣o’, ’␣O’, ’ó’, ’ö’, ’ô’, ’õ’, ’ő’, ’ò’, …
4	35	’e’	’E’, ’e’, ’␣e’, ’␣E’, ’é’, ’è’, ’␣é’, ’ę’, ’ě’, ’ê’, …
5	30	’i’	’I’, ’i’, ’␣I’, ’␣i’, ’í’, ’ì’, ’î’, ’ı̄’, ’ï’, …